

# A recuperação de pastagens pode conter o desmatamento no Brasil? Evidências de um modelo microeconômico dinâmico

Shai Oliveira-Vaz \*      Orientação: Marcelo Sant'Anna †  
Escola Brasileira de Economia e Finanças ‡

## Resumo

Este artigo analisa a recuperação de pastagens e seu potencial de reduzir o desmatamento no Brasil, utilizando um modelo dinâmico estrutural para analisar as decisões de uso da terra. O modelo incorpora tanto a margem extensiva, onde a melhoria da qualidade das pastagens está associada a menores taxas de conversão, quanto a margem intensiva, onde o aumento da produtividade incentiva uma maior conversão de terra. Ao desagregar esses efeitos, avalio empiricamente seu impacto líquido no desmatamento e nas emissões de carbono. Utilizando dados detalhados sobre degradação de pastagens, mudanças no uso da terra e sistemas de pecuária, estimo os parâmetros do modelo e avalio dois cenários contrafactuais. O primeiro analisa uma política de recuperação de pastagens, enquanto o segundo avalia um imposto sobre o carbono que internaliza o custo social das emissões. Os resultados indicam que, embora a recuperação de pastagens reduza o desmatamento, parte significativa de seus benefícios é diminuída pelos incentivos decorrentes do aumento dos retornos da conversão de terra. Em contraste, impostos sobre o carbono, mesmo modestos, alcançam reduções substanciais no desmatamento e nas emissões. Esses resultados destacam a eficácia limitada da recuperação de pastagens como solução isolada e sugerem que abordagens que integrem a precificação de carbono podem oferecer maior potencial para mitigar o desmatamento e alcançar as metas climáticas.

---

\*shai.vaz@fgv.br (21) 96616-5348

†marcelo.santanna@fgv.br (21) 3799-5832

‡gradeco@fgv.br (21) 3799-5594

Praia de Botafogo, 190 - 11º andar, Rio de Janeiro - RJ - Brasil

# 1 Introdução

A agricultura no Brasil desempenha um papel central na economia do país e contribui substancialmente para a cadeia global de abastecimento de alimentos (Calil et al. 2019). No entanto, a expansão da fronteira agrícola tem convertido grandes áreas de vegetação natural em pastagens e lavouras. As mudanças no uso da terra respondem pela maior parte das emissões brasileiras de gases de efeito estufa, representando metade das emissões dos últimos anos (Clima 2023). O desmatamento também causa a degradação de ecossistemas vitais, perda de biodiversidade e redução do potencial de sequestro de carbono.

A pecuária está no centro desse processo. Somente na Amazônia, onde se encontra a maior parte do estoque de biomassa de carbono do Brasil, 75% das emissões de uso da terra são atribuídas às atividades pecuárias. Quando todas as emissões causadas pela pecuária são consideradas em conjunto, agregando queimadas para manutenção de pastagens e fermentação entérica à mudança no uso da terra, essas atividades representam aproximadamente metade de *todas* as emissões brasileiras (Bustamante et al. 2012). Com a demanda global projetada para aumentar (FAO 2017), a sustentabilidade e a produtividade do setor agropecuário brasileiro tornam-se questões prementes. Um ponto crítico nesse contexto é a degradação das pastagens, que está associada à redução da capacidade de suporte, à diminuição da produtividade e à maior dependência de novas áreas de terra.

A relação entre produtividade agrícola e mudança no uso da terra tem sido amplamente debatida na literatura, com dois arcabouços teóricos opostos moldando a discussão. Por um lado, a *hipótese de Borlaug* argumenta que ganhos de produtividade reduzem a pressão para conversão de terras naturais, permitindo maior produção a partir da área já cultivada. Por outro lado, o *paradoxo de Jevons* destaca a possibilidade de que melhorias na eficiência aumentem o uso de recursos ao reduzir os custos de produção e incentivar a expansão. Esses arcabouços são particularmente relevantes para compreender o papel da recuperação de pastagens na redução do desmatamento, uma vez que a melhoria da qualidade das pastagens pode ter tanto efeitos de conservação de terra quanto de expansão territorial.

Embora o potencial de aumento da produtividade na agropecuária brasileira tenha sido amplamente documentado (Arantes et al. 2018; Cerri et al. 2018; Strassburg et al. 2014), particularmente por meio da recuperação de pastagens (Carlos et al. 2022; Dias-Filho 2012; Feltran-Barbieri et al. 2021; Santos et al. 2022), e apesar de sua proeminência nas discussões políticas <sup>1</sup>, a eficácia da recuperação de pastagens como estratégia de mitigação do desmatamento permanece amplamente não testada<sup>2</sup>.

A literatura frequentemente assume que a restauração de pastagens degradadas reduz a pressão para conversão de novas terras e desencoraja o desmatamento em regiões de fronteira. No entanto, essas suposições negligenciam a possibilidade de que a maior qualidade

---

<sup>1</sup>Por exemplo, o Programa Nacional de Conversão de Pastagens Degradadas (Brasil 2023)

<sup>2</sup>Pelo que tenho conhecimento, este é um dos primeiros trabalhos a testar essa hipótese em economia, particularmente alavancando métodos recentes de organização industrial empírica. Algumas pesquisas ecológicas também estudaram esse tema, sugerindo que políticas de intensificação podem ser ineficazes para conter o desmatamento (Müller-Hansen et al. 2019).

das pastagens possa aumentar os retornos da terra, incentivando assim sua expansão. Essa lacuna destaca a necessidade de uma análise empírica rigorosa para separar esses efeitos concorrentes e avaliar suas implicações para as políticas públicas.

Este artigo aborda essa lacuna na literatura ao desenvolver um modelo econômico que contabiliza explicitamente os efeitos duplos da qualidade das pastagens sobre as decisões de uso da terra. Emprego uma abordagem econométrica estrutural, amplamente utilizada na organização industrial empírica e na economia ambiental. Especificamente, desenvolvo um modelo dinâmico de escolha discreta-contínua no qual os proprietários de terra tomam decisões simultaneamente em duas margens: uma escolha discreta sobre o uso da terra (margem extensiva) e uma escolha contínua sobre a taxa de lotação do rebanho (margem intensiva). Ao estimar os parâmetros desse modelo, sou capaz de avaliar como melhorias na qualidade das pastagens influenciam ambas as margens e quantificar a magnitude relativa dos efeitos de Borlaug e Jevons, estimando seu impacto líquido sobre o desmatamento e as emissões de carbono.

Utilizando o modelo estimado, realizo análises contrafactuais para avaliar dois cenários de política. O primeiro considera uma política abrangente de recuperação de pastagens, que estabelece uma participação mínima de pastagens de alta qualidade em cada município. O segundo explora o impacto de um uso mais eficiente do carbono, alcançado por meio da internalização do custo social das emissões de carbono via um imposto sobre carbono. Esses cenários são projetados para capturar mecanismos contrastantes e avaliar sua efetividade relativa: o primeiro enfatiza melhorias na qualidade da terra, enquanto o segundo aborda diretamente as externalidades associadas à conversão de terras.

Este estudo contribui para a literatura ao apresentar uma exploração empírica preliminar dos efeitos concorrentes da recuperação de pastagens sobre o desmatamento, oferecendo uma perspectiva mais detalhada sobre os trade-offs envolvidos. A abordagem dinâmica estrutural fornece um arcabouço para entender os mecanismos que impulsionam as decisões de uso da terra e avaliar os impactos potenciais das intervenções políticas. Embora essas descobertas sejam específicas ao contexto brasileiro de expansão da pecuária e conservação de florestas tropicais, elas podem oferecer insights valiosos para a formulação de políticas voltadas ao equilíbrio entre produtividade agrícola, sustentabilidade ambiental e objetivos climáticos.

## 2 Revisão da Literatura

### 2.1 Produtividade e desmatamento

Esta pesquisa contribui para o debate sobre os impactos da melhoria da produtividade agrícola no desmatamento. A relação entre esses fatores é teoricamente ambígua (Balboni et al. 2023; Jayachandran 2022; Kaimowitz et al. 1998), com evidências empíricas apontando tanto para efeitos mitigadores quanto para efeitos amplificadores.

Por um lado, a *hipótese de Borlaug* sugere que ganhos de produtividade reduzem a necessidade de converter novas áreas ao aumentar a produção na terra já utilizada. Szerman et al.

(2022) mostraram que a eletrificação rural no Brasil elevou a produtividade agrícola, incentivando a transição da pecuária para lavouras e reduzindo o desmatamento. De forma semelhante, Abman et al. (2024) encontraram que um programa de extensão agrícola em Uganda levou à adoção de tecnologias intensivas, freando a perda florestal.

Por outro lado, o *paradoxo de Jevons* destaca que melhorias na eficiência podem aumentar a demanda por recursos, pois a redução dos custos de produção eleva os lucros esperados e incentiva a expansão da terra utilizada. Carreira et al. (2024) demonstraram que o avanço da soja transgênica no Brasil resultou na expansão da área plantada, principalmente entre produtores com menos restrições de capital. Da mesma forma, programas de desenvolvimento rural na Gâmbia (Hess et al. 2021) e nas Filipinas (Pagel 2022) estimularam investimentos que aumentaram a produtividade, mas também aceleraram o desmatamento.

Neste estudo, desenvolvo um modelo estrutural que estima os efeitos da recuperação de pastagens degradadas sobre as margens intensiva e extensiva da produção pecuária. O modelo permite avaliar se a recuperação de pastagens reduz a necessidade de expansão de terras ou se, ao contrário, o aumento da produtividade eleva os retornos e incentiva o desmatamento.

## 2.2 Ciclos pecuários

Esta pesquisa também se relaciona com a literatura sobre ciclos pecuários, iniciada por Jarvis (1974), que modelaram o gado como um bem de capital e os pecuaristas como gestores de portfólio. Eles mostram que as respostas dos produtores a choques de preços podem ser complexas e ambíguas, pois decisões intertemporais afetam o tamanho do rebanho e os padrões de abate.

Trabalhos subsequentes expandiram essa abordagem. Rosen (1987) enfatizaram a importância da gestão do estoque de rebanho na dinâmica da oferta, enquanto Rosen et al. (1994) aplicaram séries temporais para estudar a evolução demográfica dos rebanhos nos EUA. Mais recentemente, Goel (2020) usaram um modelo de momentos generalizados para demonstrar como choques temporários e permanentes nos preços da carne podem ter efeitos opostos sobre o desmatamento.

O modelo que desenvolvo incorpora esses elementos, tratando o gado como um ativo de capital e considerando a dinâmica das decisões de abate e manejo do rebanho. Isso permite analisar como choques de preços e políticas ambientais influenciam as decisões dos produtores ao longo do tempo.

## 2.3 Uso da terra e desmatamento

Este estudo se alinha à literatura que utiliza modelos de escolha discreta para analisar dinâmicas de uso da terra e impactos ambientais. Trabalhos clássicos como Chomitz et al. (1996) e Pfaff (1999) exploraram os determinantes do desmatamento tropical, destacando o papel das redes de transporte. Souza-Rodrigues (2019) comparou políticas de conservação na Amazônia e mostrou que incentivos econômicos são significativamente mais eficazes do que medidas de comando e controle.

Modelos de escolha discreta dinâmicos<sup>3</sup> representam um avanço metodológico importante, capturando melhor as decisões intertemporais dos produtores rurais. Scott (2014) foi pioneiro na aplicação desses modelos à agricultura, demonstrando que elasticidades de longo prazo da conversão de terras são muito maiores do que aquelas estimadas em modelos estáticos.

Pesquisas recentes aplicam essa abordagem para estudar questões ambientais. Araujo, Costa, et al. (2020) analisaram políticas eficientes de conservação florestal na Amazônia, considerando a internalização dos custos sociais do desmatamento. Hsiao (2024) utilizaram um modelo dinâmico de escolha discreta-contínua para avaliar políticas no setor de óleo de palma. Já Barrozo (2024) investigaram o impacto do poder de mercado na pecuária e nas emissões associadas, combinando modelos estáticos e dinâmicos de escolha discreta.

Além disso, esta pesquisa se relaciona com estudos recentes desenvolvidos na minha instituição<sup>4</sup>, como os de Pacheco (2021) e Pimentel (2021). O primeiro analisa os impactos de preços e mudanças climáticas sobre a oferta agrícola, enquanto o segundo examina a Moratória da Soja e sua influência sobre a intensificação pecuária no Cerrado.

Neste estudo, desenvolvo um modelo dinâmico de escolha discreta-contínua para analisar a produção pecuária e o uso da terra, combinando elementos da literatura recente (Araujo, Costa, et al. 2024; Hsiao 2024). No modelo, um produtor decide entre manter a vegetação nativa ou convertê-la em pastagem, considerando retornos dinâmicos. O retorno da vegetação natural depende do estoque de biomassa de carbono, enquanto os retornos da pastagem são determinados pela gestão intertemporal do rebanho. Essa abordagem permite avaliar como políticas de recuperação de pastagens e precificação do carbono afetam o desmatamento e a sustentabilidade da pecuária no Brasil.

### 3 Metodologia

Conceituo a tomada de decisão do pecuarista como um problema composto por três dimensões: (i) a decisão de uso da terra, determinando se converter a vegetação nativa em pastagem; (ii) a decisão na margem intensiva, referente à taxa de lotação (isto é, o número de animais mantidos no campo); e (iii) decisões de consumo no curto prazo, como a quantidade de animais enviados para o abate e o momento dessas ações. Embora interdependentes, essas decisões representam aspectos distintos do processo produtivo. No modelo, a etapa (i) corresponde à margem extensiva, enquanto as etapas (ii) e (iii) são tratadas conjuntamente na margem intensiva.

A modelagem da margem intensiva baseia-se em métodos de otimização contínua em contextos dinâmicos (Hall 1978; Stokey et al. 1989). Os pecuaristas resolvem um problema considerando estoques observáveis e uma função de consumo não observável, latente para o economista. No entanto, o processo de otimização gera uma equação de Euler definida sobre variáveis observáveis, viabilizada por uma equação de movimento que vincula as decisões

<sup>3</sup>Esses modelos seguem a estrutura teórica de Rust (1987) e foram refinados por Hotz et al. (1993), Aguirregabiria et al. (2002) and Aguirregabiria et al. (2007) e Arcidiacono and Miller (2011).

<sup>4</sup>FGV EPGE

de consumo à dinâmica do estoque total.

Para a margem extensiva, utilizo um modelo de escolha discreta dinâmica com uma estrutura de escolha terminal, inspirado em Hsiao (2024) e Araujo, Costa, et al. (2024). Essa abordagem segue os princípios de Arcidiacono and Ellickson (2011) e Aguirregabiria et al. (2010), com fundamentação teórica em Hotz et al. (1993) e Arcidiacono and Miller (2011). O modelo compara as decisões de conversão de terra entre os períodos  $t$  e  $t+1$ . Dado o caráter prospectivo da otimização do manejo do rebanho, vale a condição de dependência finita, permitindo a derivação de um análogo discreto da equação de Euler.

A utilização da equação de Euler na estimação de modelos de escolha discreta dinâmica apresenta vantagens, pois elimina a necessidade de calcular diretamente os valores de continuação, uma exigência de outros métodos recursivos. Essa abordagem evita a complexidade de derivar probabilidades condicionais de escolha (CCPs) a partir das funções de valor e permite que o modelo seja estimado por meio de técnicas lineares convencionais.

### 3.1 Margem intensiva

Começo com o problema de um pecuarista  $i$  que gerencia um lote de terra já coberto por pastagens, no município  $m$ , localizado na região  $g$ . Ele inicia o período  $t$  com um estoque de animais  $h_{it}$  herdado do período anterior. Seu problema dinâmico consiste em maximizar o lucro a cada período. Escrevo-o como o seguinte problema de programação dinâmica:

$$\mathcal{V}(h_{it}; \mathbf{s}_{mt}) = \max_{c_{it}} \{r(c_{it}; \mathbf{s}_{mt}) - \psi(h_{it}; \mathbf{s}_{mt}) + \beta \mathbb{E}_t[\mathcal{V}(h_{it+1}; \mathbf{s}_{mt+1})]\}$$

Onde  $r(\cdot)$  é uma função de receita e  $\psi(\cdot)$  representa os custos. A variável de controle  $c_{it}$  representa o consumo do estoque  $h_{it}$ . Isso pode ser interpretado como a venda de gado para abate, reprodução e engorda, líquida de compras de novos animais.

Isso significa que permitimos que o consumo seja positivo ou negativo. Se o consumo for negativo, o pecuarista incorre em custos, pagando  $p_{mt}$  por cada animal (líquido) comprado. Se o consumo for positivo, ele obtém receita vendendo cada animal (líquido) ao mesmo preço  $p_{mt}$ .

O vetor  $\mathbf{s}_{mt} = \{p_{mt}, \mathbf{x}_{mt}, \xi_{mt}, \varepsilon_{mt}, g\}$  agrupa as variáveis de estado no tempo  $t$ . Inclui os preços locais  $p_{mt}$  e um vetor de fatores de custo  $\mathbf{x}_{mt}$ . Assumo que os pecuaristas são tomadores de preço. Também incluo choques a nível de mercado  $\xi_{mt}$  e  $\varepsilon_{mt}$ , relacionados às margens extensiva e intensiva. Finalmente,  $g$  denota a região do pecuarista  $i$ .

**Assumption 1.** *O tamanho do rebanho  $h_{it+1}$  segue uma lei de movimento dada por:*

$$h_{it+1} = (1 + \phi)h_{it} - c_{it}$$

Assumo que o rebanho do pecuarista ao final do período  $t$  segue uma lei de movimento que depende de uma taxa de crescimento biológico do rebanho herdado e dos níveis de consumo durante  $t$ . O parâmetro  $\phi$  é definido como a taxa de crescimento biológico do rebanho. Ele

pode ser considerado o resultado líquido das taxas de natalidade e mortalidade sob práticas reprodutivas ótimas, cuja análise não realizo aqui.

Em particular, especifico as seguintes formas funcionais para  $r(\cdot)$  e  $\psi(\cdot)$ . As receitas dependem linearmente do consumo  $c_{it}$  e dos preços locais  $p_{mt}$ . Assumo que os custos são crescentes e convexos em relação ao rebanho herdado  $h_{it}$ . Também trato a heterogeneidade não observada com a inclusão de efeitos fixos regionais e uma tendência temporal como fatores de custo.

$$r(c_{it}; \mathbf{s}_{mt}) = \alpha_p p_{mt} c_{it} \quad (1)$$

$$\psi(h_{it}; \mathbf{s}_{mt}) = \left[ \frac{1}{2} \delta h_{it} + \mathbf{x}_{mt} \gamma_x + \gamma_g + \gamma_t t + \varepsilon_{mt} \right] h_{it}$$

### 3.1.1 Equação de regressão estrutural para a margem intensiva

Resolvo o problema da margem intensiva como de costume para problemas de programação dinâmica contínua. Primeiro, assumo uma solução interior, aproveitando a estrutura de custos convexos e receitas lineares. Em seguida, tomo a condição de primeira ordem para o problema de maximização do lado direito e a condição do envelope da função valor. Combinando essas duas, posso derivar uma equação de Euler sobre as variáveis observáveis. Assumo expectativas racionais para obter um modelo de regressão em  $h_{mt+1}$ , considerando valores realizados como medidas ruidosas de expectativas. A derivação pode ser encontrada no Apêndice C.1.

$$\begin{aligned} h_{mt+1} = & \alpha_p \frac{(1 + \phi)}{\delta} p_{mt+1} - \alpha_p \frac{1}{\delta} \frac{1}{\beta} p_{mt} \\ & - \mathbf{x}_{mt+1} \frac{\gamma_x}{\delta} - \frac{\gamma_g}{\delta} - (t + 1) \frac{\gamma_t}{\delta} \\ & + \eta_{mt} + \mu_{mt} \end{aligned} \quad (2)$$

Onde  $\eta_{it}$  é um erro de expectativa, definido como a diferença entre valores esperados e realizados das variáveis observáveis. E  $\mu_{it}$  é o erro estrutural. Eles são dados por:

$$\begin{aligned} \eta_{mt} = & \alpha_p \frac{(1 + \phi)}{\delta} \left[ \mathbb{E}_t[p_{mt+1}] - p_{mt+1} \right] \\ & - \frac{\gamma_x}{\delta} \left[ \mathbb{E}_t[\mathbf{x}_{mt+1}] - \mathbf{x}_{mt+1} \right] \\ & - \frac{1}{\delta} \left[ \mathbb{E}_t[\varepsilon_{mt+1}] - \varepsilon_{mt+1} \right] \\ \mu_{mt} = & -\frac{1}{\delta} \varepsilon_{mt+1} \end{aligned} \quad (3)$$



## 3.2 Margem extensiva

Agora descrevo a decisão de uso da terra de um pecuarista. O uso atual da terra em um lote é dado por  $k \in \{0, 1\}$ , onde 0 representa vegetação natural e 1 representa pastagens. Se  $k = 0$ , o lote começa  $t$  florestado e o agente enfrenta uma escolha discreta  $j \in J = \{0, 1\}$ , decidindo sobre sua margem extensiva. Quando os agentes decidem sobre essa margem, eles enfrentam choques não observáveis  $\nu_{it} = \nu_{ijt}$ ,  $j \in \{0, 1\}$ . Para simplicidade, aqui agrupo os vetores  $\omega_{it}$  e  $\varepsilon_{it}$ , de variáveis observáveis e não observáveis, em um único vetor de estado  $s_{mt}$ .

Se os pecuaristas escolhem  $j = 0$ , eles extraem retornos das atividades florestais e enfrentam a mesma escolha no próximo período. Alternativamente, se escolhem  $j = 1$ , o lote é desmatado e convertido em pastagens. Os agentes pagam um custo de conversão e extraem retornos da pecuária, para a qual enfrentam escolhas de margem intensiva, primeiro no tamanho inicial do rebanho e depois nas taxas de consumo a cada período. O desmatamento é uma ação terminal e encerra o problema de escolha discreta.

Assumo utilidade aleatória, independência condicional e erros do tipo valor extremo. Essas suposições são detalhadas abaixo e são padrão na literatura de escolha discreta dinâmica (Arcidiacono and Ellickson 2011).

**Assumption 2.** *Os pagamentos condicionais do agente  $\pi(j, s_{mt}, \nu_{it})$  para a margem extensiva são separáveis aditivamente no choque não observável  $\nu_{it}$ .*

**Assumption 3.** *As variáveis de estado seguem um processo de Markov e são independentes dos choques não observáveis da margem extensiva, condicional ao estado atual.*

$$F(s_{mt+1} \mid s_{mt}, j, \nu_{it}) = F(s_{mt+1} \mid s_{mt})$$

**Assumption 4.** *Os choques da margem extensiva  $\nu_{ijt}$  são independentes e identicamente distribuídos ao longo do tempo e das escolhas, seguindo uma distribuição do tipo Valor Extremo Tipo I.*

### 3.2.1 Equação de regressão estrutural para a margem extensiva

Uma derivação detalhada para a seguinte condição pode ser encontrada no Apêndice C.2. O lado direito representa o valor de corte acima do qual o pecuarista prefere converter o lote para pastagem em  $t$  em vez de mantê-lo florestado e convertê-lo em  $t + 1$ .

$$\log\left(\frac{\rho_{mt}}{1 - \rho_{mt}}\right) - \beta \log(\rho_{mt+1}) + \beta\gamma = -\Psi(s_{mt}) + \beta\Psi(s_{mt+1}) \quad (4)$$

$$- \alpha_b b_m + \delta \frac{\beta}{2} (h_{mt+1})^2 \quad (5)$$

$$+ \eta_{it}^e + \mu_{it}^e \quad (6)$$



Onde  $\eta_{it}^e$  é um erro de expectativa, e  $\mu_{it}^e$  um erro estrutural, dados por:

$$\begin{aligned}\eta_{mt}^e &= \beta \left[ \mathbb{E}_t[\log(\rho_{mt+1})] - \log(\rho_{mt+1}) \right. \\ &\quad + \mathbb{E}_t[\Psi(\mathbf{s}_{mt+1})] - \beta\Psi(\mathbf{s}_{mt+1}) \\ &\quad \left. - [\mathbb{E}_t[\xi_{mt+1}] - \xi_{mt+1}] \right] \\ \mu_{mt}^e &= -\beta\xi_{mt+1}\end{aligned}\tag{7}$$

Em seguida, forneço mais estrutura à função de custo da margem extensiva, incorporando explicitamente fatores análogos aos utilizados na especificação de custo da margem intensiva. Isso serve a dois propósitos principais. Primeiro, captura o impacto de uma maior qualidade das pastagens no uso de insumos limitados, como fertilizantes ou crédito, que influenciam os custos de conversão da terra. Isso testa a hipótese de Borlaug, de que melhorias na produtividade podem reduzir a expansão da terra. Segundo, fornece controles para outros determinantes dos custos de conversão, melhorando a consistência do modelo. Especificamente, defino a função  $\Psi(\cdot)$  como:

$$\Psi(\mathbf{s}_{mt}) = \mathbf{x}_{it}\gamma_x^e + \gamma_g^e + \gamma_t^e t$$

Portanto, o termo  $-\Psi(\mathbf{s}_{mt}) + \beta\Psi(\mathbf{s}_{mt+1})$  pode ser escrito da seguinte forma:

$$\begin{aligned}-\Psi(\mathbf{s}_{mt}) + \beta\Psi(\mathbf{s}_{mt+1}) &= [\beta\mathbf{x}_{it+1} - \mathbf{x}_{it}]\gamma_x^e \\ &\quad + (\beta - 1)\gamma_g^e \\ &\quad + \gamma_t^e (\beta + (\beta - 1)t)\end{aligned}$$

Finalmente, obtenho a seguinte equação de regressão para a margem extensiva.

$$\begin{aligned}\log\left(\frac{\rho_{mt}}{1 - \rho_{mt}}\right) - \beta \log(\rho_{mt+1}) + \beta\gamma &= [\beta\mathbf{x}_{it+1} - \mathbf{x}_{it}]\gamma_x^e \\ &\quad + (\beta - 1)\gamma_g^e + \gamma_t^e (\beta + (\beta - 1)t) \\ &\quad - \alpha_b b_m + \delta \frac{\beta}{2} (h_{mt+1})^2 \\ &\quad + \eta_{it}^e + \mu_{it}^e\end{aligned}$$

(8)

## 4 Identificação e estimação

### 4.1 Configuração geral

Este capítulo detalha a estratégia de identificação e a abordagem de estimação para as equações estruturais (de Euler) do modelo. As equações são estimadas no nível municipal, focando tanto na margem intensiva quanto na margem extensiva da pecuária. A identificação dos parâmetros

baseia-se em uma combinação de efeitos fixos, variáveis instrumentais e calibração, com pressupostos-chave fundamentados na literatura.

Para a **margem intensiva**, estimo a equação de regressão 2 desenvolvida no modelo estrutural. Nesta equação,  $h_{mt+1}$  denota o tamanho do rebanho no início do período  $t+1$ , capturando o estoque de gado disponível para a produção futura. Os termos  $p_{mt}$  e  $p_{mt+1}$  correspondem aos preços locais do gado nos tempos  $t$  e  $t+1$ , respectivamente, refletindo as condições de mercado que influenciam as decisões dos pecuaristas. A variável  $x_{mt+1}$  representa um vetor de covariáveis observáveis — como temperatura, acesso ao mercado, custo de transporte e qualidade da pastagem — que afetam os custos de produção. O termo  $\gamma_g$  captura os efeitos fixos de bioma, os quais consideram diferenças nos custos e restrições do manejo do rebanho entre ecossistemas, mitigando vieses decorrentes da heterogeneidade regional não observada. O parâmetro  $\gamma_t$  captura uma tendência temporal para refletir dinâmicas ao longo do tempo. Por fim,  $\eta_{mt}$  e  $\mu_{mt}$  representam um erro de expectativa e um erro estrutural que captura choques idiossincráticos, respectivamente.

Para a **margem extensiva**, estimo a equação estrutural 8 do modelo. Nesta equação,  $\rho_{mt}$  representa a probabilidade de conversão de uma área de terra em pastagem no tempo  $t$  dentro do município. A variável  $x_{it}$  é o mesmo vetor de covariáveis que influenciam os custos dos pecuaristas, incluindo fatores como a qualidade da pastagem. O termo  $b_m$  mede a densidade de biomassa de carbono no município, conforme medido no ano 2000. O tamanho ótimo do rebanho para o período subsequente,  $h_{mt+1}$ , conecta a margem extensiva às expectativas futuras de manejo do rebanho derivadas da margem intensiva. Finalmente,  $\eta_{it}^e$  e  $\mu_{it}^e$  capturam o erro de expectativa e os choques idiossincráticos nas decisões de uso da terra.

Os erros de expectativa, que refletem a diferença entre expectativas e realizações, exigem o uso de instrumentos para lidar com possíveis problemas de endogeneidade. Para a margem intensiva, conforme descrito nas equações 3, os erros de expectativa estão inerentemente correlacionados com preços e fatores de custo que variam no tempo, especialmente a qualidade da pastagem. Na margem extensiva, conforme indicado nas equações 7, a endogeneidade surge unicamente da correlação entre os erros de expectativa e os fatores de custo. Para tratar essas questões, utilizo como instrumento para os preços uma variável shift-share derivada de choques exógenos às importações agrícolas da China. Para a qualidade da pastagem, utilizo como instrumento os valores mínimos mensais do Índice de Severidade de Seca de Palmer (PDSI) do ano anterior, aplicável a ambas as margens. Uma descrição detalhada da construção desses instrumentos é fornecida no Apêndice C.3.

## 4.2 Dados utilizados

Emprego dados de satélite de alta resolução sobre uso da terra e qualidade da pastagem, desenvolvidos pelo *Projeto MapBiomass*. O Censo Agropecuário do IBGE fornece dados sobre o rebanho bovino por município, os quais complemento com informações da Pesquisa da Pecuária Municipal, também do IBGE. Os preços locais do gado são estimados combinando dados de vendas e receitas do Censo com o Indicador do Boi Gordo do CEPEA. Utilizo

Table 1: Intensive Margin IV Regression Results

	$h_{mt+1}$	Parameters
$p_{mt}$	-0.0188*** 0.0071	$-\frac{\alpha_p}{\delta\beta}$
$p_{mt+1}$	0.0198*** 0.0071	$\frac{\alpha_p(1+\phi)}{\delta}$
Pasture Quality ( $x_{mt+1}$ )	1.3111** 0.5629	$-\frac{\gamma_{pasture}}{\delta}$
Year	0.2904** 0.1324	$-\frac{\gamma_t}{\delta}$
Num.Obs.	6487	
Controls	Temp.; Past.Suit.; Mkt.Acc.; Transp.Cost.	
Fixed Effects	Biome	
F (2nd stage)	108.51	
F (1st stage: $p_{mt}$ )	49.9809	
F (1st stage: $p_{mt+1}$ )	47.7408	
F (1st stage: Past. Qual.)	38.0575	
Clustered SE	Yes (Municipality)	

\*  $p \leq 0.1$ , \*\*  $p \leq 0.05$ , \*\*\*  $p \leq 0.01$

Standard errors clustered at the municipality level. Biome fixed effects. Controls: Pasture suitability, market access, transportation cost, average minimum and average maximum temperatures. Shift-share variables used as instruments for prices. Palmer drought severity index (PDSI) used as instrument for pasture quality.

polígonos municipais temporalmente consistentes ao longo da análise. Para construir instrumentos de preço, utilizo dados de fluxos comerciais internacionais por produto do BACI CEPII e dados sobre biomassa de carbono acima do solo do World Forest Watch para estimar a valoração do carbono pelos pecuaristas. Como covariáveis, utilizo controles climáticos, custos de transporte, acesso ao mercado e adequação da pastagem. Para uma descrição detalhada das fontes de dados utilizadas, consulte o Apêndice A.

### 4.3 Resultados

A Tabela 1 apresenta os resultados da segunda etapa da estimação para a regressão com variável instrumental da equação estrutural da margem intensiva, incorporando efeitos fixos de bioma e um conjunto completo de controles. Os resultados correspondentes da primeira etapa são fornecidos no Apêndice D.1. Como verificação de robustez, o Apêndice D.2 inclui resultados de duas especificações adicionais que empregam efeitos fixos municipais, com e sem instrumentação. Os coeficientes nessas especificações alternativas mantêm o mesmo sinal que os resultados principais, mas suas magnitudes são atenuadas.

Table 2: Extensive Margin IV Regression Results

	$\log\left(\frac{\rho_{mt}}{1-\rho_{mt}}\right) - \beta \log(\rho_{mt+1}) + \beta\gamma$	Parameters
$\frac{\beta}{2}(h_{mt+1})^2$	0.2964** (0.1469)	$\delta$
Pasture Quality ( $\beta x_{mt+1} - x_{mt}$ )	6.8196*** (0.7412)	$\gamma_{pasture}^e$
$b_m$	0.0011*** (0.0002)	$-\alpha_b$
$(\beta + (\beta - 1)t)$	-0.0762*** (0.0234)	$\gamma_t^e$
Num.Obs.	6210	
Controls	Temp.; Past.Suit.; Mkt.Acc.; Transp.Cost.	
F (2nd stage)	15.7038	
F (1st stage: Past. Qual.)	715.7339	
Clustered SE	Yes (Municipality)	

\* p | 0.1, \*\* p | 0.05, \*\*\* p | 0.01

Standard errors clustered at the municipality level. Controls: Pasture suitability, market access, transportation cost, average minimum and average maximum temperatures. All time varying controls have been calculated as an inter-temporal difference of the form  $\beta x_{mt+1} - x_{mt}$ . Palmer Drought Severity Index (PDSI) used as instrument for the intertemporal difference in pasture quality.

Os resultados da segunda etapa da estimação da equação estrutural da margem extensiva podem ser vistos na Tabela 8, também com efeitos fixos de bioma e controles. O Apêndice D.3 exibe os resultados da primeira etapa para este modelo. Exercícios empíricos alternativos<sup>5</sup> com dados de pesquisas de maior frequência, porém menos precisos, descritos na Seção A.2, são apresentados no Apêndice D.4, com e sem instrumentos. Os resultados são próximos aos da especificação principal, especialmente quando os instrumentos são empregados.

O modelo estrutural completo é subidentificado em seus parâmetros. A identificação é alcançada por meio da calibração do fator de desconto intertemporal  $\beta$ . Essa é uma prática comum na literatura, pois o fator de desconto geralmente não é identificado em modelos dinâmicos (Magnac et al. 2002). Assumo  $\beta = 0.9$ . Com essa calibração, as estimativas da margem intensiva permitem identificar os parâmetros  $(\phi, \alpha_p/\delta, \gamma_x/\delta, \gamma_g/\delta, \gamma_t/\delta)$ . E a partir das estimativas da margem extensiva, identifico  $(\delta, \alpha_b, \gamma_x^e, \gamma_g^e, \gamma_t^e)$ . Em seguida, utilizo  $\delta$  para extrair  $(\alpha_p, \gamma_x, \gamma_g, \gamma_t)$  em níveis e divido por  $\alpha_p$  para calcular todos os parâmetros relevantes em termos

<sup>5</sup>Note que para a margem extensiva um parâmetro crucial ( $\alpha_b$ ) é estimado a partir de uma variável específica do município e invariável no tempo ( $b_m$ ). Portanto, um exercício com efeitos fixos municipais não é viável para a margem extensiva como foi para a margem intensiva, pois o parâmetro de biomassa de carbono seria absorvido pelos efeitos fixos.

Table 3: Structural Parameters

Parameter	Value	Scaled by $\alpha_p$ (R\$)
$\phi$	0.1684	
$\delta$	0.2964	
$\alpha_p$	0.0050	
$\alpha_b$	-0.0011	-0.22
<b>Intensive margin cost factors</b>		
$\gamma_{pasture}$	-0.3887	-77.29
$\gamma_t$	-0.0861	-17.12
$\gamma_g : g = amazonia$	174.7659	34755.92
$\gamma_g : g = caatinga$	174.8613	34774.89
$\gamma_g : g = cerrado$	174.8432	34771.29
$\gamma_g : g = mata atlantica$	174.8058	34763.86
$\gamma_g : g = pampa$	174.8677	34776.17
$\gamma_g : g = pantanal$	174.7419	34751.14
<b>Extensive margin cost factors</b>		
$\gamma_{pasture}^e$	6.8196	1356.22
$\gamma_t^e$	-0.0762	-15.16
$\gamma_g^e : g = amazonia$	157.3413	31290.67
$\gamma_g^e : g = caatinga$	154.0151	30629.18
$\gamma_g^e : g = cerrado$	155.2466	30874.09
$\gamma_g^e : g = mata atlantica$	156.0026	31024.44
$\gamma_g^e : g = pampa$	156.1444	31052.64
$\gamma_g^e : g = pantanal$	153.6928	30565.09

monetários. Os resultados são apresentados na Tabela 3.

#### 4.4 Comentários

Os coeficientes estimados para preços estão alinhados com as previsões da literatura sobre ciclos pecuários. O coeficiente de  $p_{mt}$  é negativo, enquanto o coeficiente de  $p_{mt+1}$  é positivo. Isso indica que um aumento temporário nos preços atuais  $p_{mt}$ , não esperado para persistir no ano seguinte, motiva os produtores a aumentar o consumo do rebanho no presente, reduzindo assim o tamanho do rebanho no período subsequente. Por outro lado, se os produtores em  $t$  antecipam um aumento de preço apenas em  $t + 1$ , eles são incentivados a reduzir o consumo atual do rebanho para capitalizar preços mais altos posteriormente, resultando em um rebanho maior no ano seguinte. Além disso, estimo uma taxa de crescimento biológico  $\phi$  de 16,84%, que é consistente com os volumes agregados de abate em relação ao rebanho nacional<sup>6</sup>.

Um coeficiente negativo para a qualidade da pastagem ( $\gamma_{pasture}$ ) na margem intensiva indica que uma qualidade inferior da pastagem em um município aumenta os custos marginais de

<sup>6</sup>Para estimativas aproximadas, pode-se aplicar a equação de evolução do estoque de gado aos dados agregados nacionais da *Pesquisa da Pecuária Municipal* e da *Pesquisa Trimestral do Abate de Animais*, ambas do IBGE, obtendo taxas de crescimento semelhantes.

manejo do rebanho, reduzindo assim as taxas ótimas de lotação. Por outro lado, uma melhoria na qualidade da pastagem diminui esses custos marginais, permitindo maiores taxas ótimas de lotação. Essa relação está alinhada com a intuição econômica, pois pastagens de melhor qualidade suportam maior produção de forragem e reduzem a necessidade de insumos por unidade de gado.

Na margem extensiva, o coeficiente para a qualidade da pastagem ( $\gamma_{pasture}^e$ ) é positivo, sugerindo uma dinâmica diferente. Uma redução na qualidade da pastagem incentiva taxas mais altas de conversão de terra, possivelmente porque os produtores procuram expandir a área disponível para pastagem para compensar a menor produtividade das pastagens existentes. Por outro lado, melhorias na qualidade da pastagem aumentam o custo efetivo da conversão de terras. Isso pode refletir uma maior demanda por insumos complementares ou maior dependência de crédito, ambos tornando a expansão menos lucrativa.

Os coeficientes dos parâmetros de tendência temporal dos custos ( $\gamma_t, \gamma_t^e$ ) são ambos negativos, indicando que os custos de manejo do rebanho e conversão de terras diminuíram entre 2006 e 2017. Isso provavelmente reflete avanços tecnológicos, melhorias na infraestrutura ou mudanças nas políticas que reduziram os custos ao longo do tempo. A queda nos custos de conversão também pode resultar da expansão das redes de transporte ou de outros desenvolvimentos que reduziram barreiras à mudança no uso da terra, como flexibilização das regulamentações ambientais.

O coeficiente próximo de zero e negativo para a biomassa de carbono ( $\alpha_b$ ) sugere que, em média, os produtores brasileiros não atribuem valor monetário implícito aos estoques de carbono. Esse achado reforça a noção de que, na ausência de incentivos políticos eficazes, a conservação de carbono desempenha um papel insignificante nas decisões de uso da terra. O resultado é ainda mais preocupante do que os achados de Araujo, Costa, et al. (2024), que encontram uma valorização pequena, mas positiva, do carbono para propriedades na Amazônia, onde políticas de comando e controle tiveram algum sucesso na redução do desmatamento. Tanto nos meus achados quanto nos deles, a valorização implícita da biomassa de carbono pelos produtores está muito abaixo do nível eficiente — aquele que se alinharia ao custo social do carbono (SCC). Uma estimativa recente de Barrage et al. (2024) coloca o SCC em \$66,00 por tonelada (em dólares de 2019), evidenciando a enorme discrepância entre a valoração privada dos produtores e o custo externo do carbono.

Na seção seguinte, realizo dois exercícios contrafactuais usando os resultados da estimação do modelo estrutural. Os parâmetros  $\gamma_{pasture}, \gamma_{pasture}^e$  e  $\delta$  são usados para simular os efeitos de um conjunto hipotético de políticas de recuperação de pastagens, separando seus impactos concorrentes nas margens intensiva e extensiva. Além disso, ao modificar o parâmetro  $\alpha_b$ , avalio as implicações de aumentar a valoração dos produtores sobre a biomassa de carbono, por meio de mecanismos como um imposto sobre o carbono, até o custo social do carbono.

Table 4: Baseline scenario

Variable	Predicted	Observed	Relative error
Land conversion ( $10^4 km^2$ )	4.3169	4.1160	0.0488
Carbon emissions (Gt $CO_2$ )	1.1724	1.1211	0.0458

## 5 Contrafactuais

### 5.1 Abordagem geral

Nesta seção, avalio dois conjuntos de políticas contrafactuais e seus impactos sobre a conversão de terras e as emissões de carbono. Esses cenários são comparados aos valores preditos pelo modelo de referência, que servem como um ponto de comparação para a análise das potenciais reduções na conversão de terras e nas emissões de carbono. Os contrafactuais representam cenários hipotéticos de políticas alternativas de recuperação de pastagens e tributação de carbono aplicadas durante o período do estudo à amostra em análise.

Diferentemente de contextos estáveis, onde um cenário de estado estacionário pode ser calculado a partir de uma distribuição estacionária de probabilidades condicionais, como em Araujo, Costa, et al. (2024), a natureza não estacionária deste estudo exige uma metodologia distinta para estimar os contrafactuais. Adoto a abordagem descrita por Hsiao (2024), desenvolvida para um contexto não estacionário semelhante.

Com esse método, introduzo perturbações de política de curto prazo, mantendo constantes as condições de mercado de longo prazo. Como os agentes são prospectivos e o modelo assume ausência de dependência de trajetória, as probabilidades condicionais de longo prazo permanecem inalteradas. Os impactos das políticas contrafactuais são estimados diretamente a partir das equações de Euler do modelo. A partir dessas equações, calculo novas probabilidades condicionais de curto prazo, retrocedendo a partir das probabilidades inalteradas de longo prazo. Essas probabilidades revisadas são então utilizadas para estimar as taxas contrafactuais de conversão de terras (multiplicando as novas probabilidades pela área do município) e as emissões contrafactuais de carbono (multiplicando a nova conversão de terras pela densidade de carbono por hectare).

Para validar o modelo, aplico a mesma abordagem de estimação sem introduzir mudanças de política, gerando previsões de referência para conversão de terras e emissões. Esse cenário de referência exhibe a conversão de milhões de hectares de vegetação natural para pastagens e bilhões de toneladas de  $CO_2$  emitidas. Essas previsões estão alinhadas com os valores observados, demonstrando a robustez do modelo. A Tabela 4 apresenta as previsões do modelo ao lado dos dados observados, com seus erros relativos. O modelo superestima ligeiramente a conversão de terras e as emissões de carbono, indicando um bom nível de precisão preditiva.



## 5.2 Recuperação de pastagens

Para o primeiro exercício contrafactual, avalio os impactos de políticas voltadas à promoção da recuperação generalizada de pastagens. Essas políticas são implementadas por meio da imposição de um limite mínimo para a participação de pastagens de alta qualidade em cada município. Especificamente, municípios onde a proporção de pastagens de alta qualidade fica abaixo do mínimo estabelecido pela política passam por esforços de recuperação para atingir esse patamar. A política eleva gradualmente esse limite em incrementos sucessivos, culminando em um cenário onde todas as pastagens da área de estudo são totalmente restauradas à alta qualidade.

Para cada cenário de política, calculo as taxas contrafactuais de conversão de terras e emissões de  $CO_2$ , comparando-as aos valores estimados pelo modelo de referência. A referência serve como um ponto de comparação, representando a conversão estimada na ausência de intervenção política. O Painel A da Tabela 5 resume a redução total da conversão de terras e o abatimento de carbono ao longo dos diferentes cenários de recuperação.

A separação das margens intensiva e extensiva no modelo estrutural permite a identificação dos efeitos concorrentes da qualidade das pastagens sobre as taxas de conversão de terras. Os resultados da estimação revelam duas dinâmicas opostas:

**Efeito Borlaug:** A maior qualidade das pastagens está associada ao aumento dos custos de conversão, conforme indicado pelo coeficiente positivo  $\gamma_{pasture}^e$  na margem extensiva. A melhoria na qualidade das pastagens desencoraja a conversão de terras ao tornar a expansão menos lucrativa, possivelmente devido à maior necessidade de insumos complementares ou a restrições de crédito mais rígidas. Isso está alinhado com a *hipótese de Borlaug*, segundo a qual ganhos de produtividade reduzem a pressão pela expansão da terra.

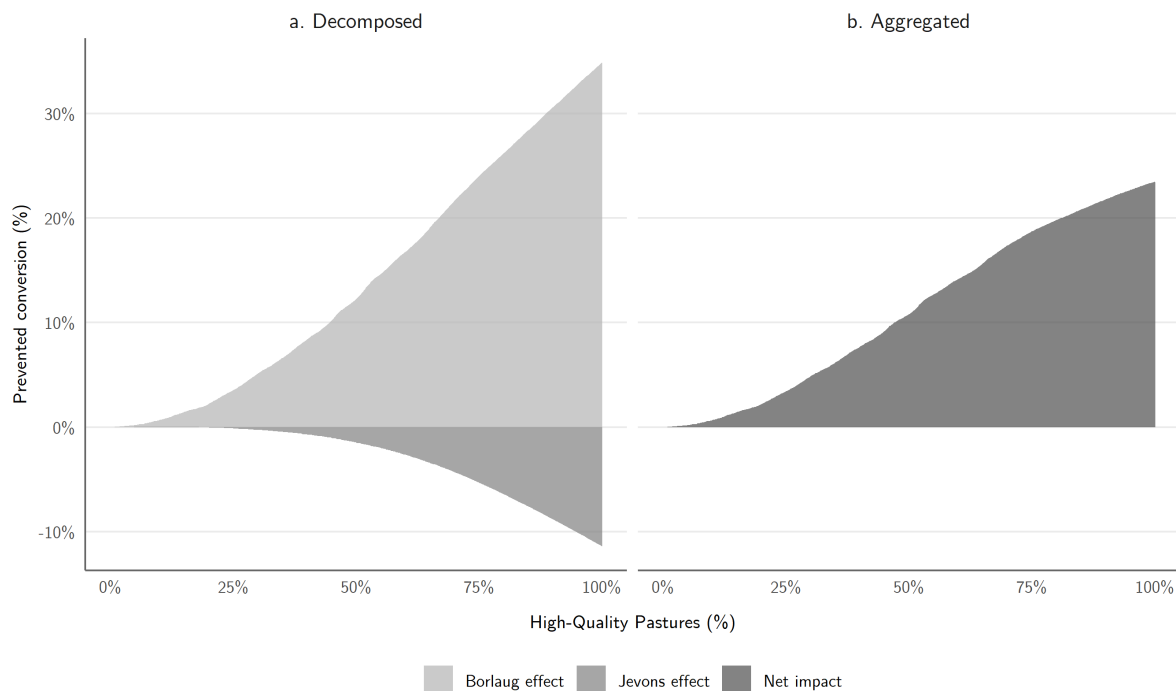
**Efeito Jevons:** Na margem intensiva, um coeficiente  $\gamma_{pasture}$  negativo indica que a melhoria da qualidade das pastagens reduz os custos marginais, elevando as taxas ótimas de lotação. Além disso, um coeficiente  $\delta$  positivo implica que taxas ótimas de lotação mais altas aumentam os retornos do uso da terra, incentivando a conversão de terras. Esse efeito reflete o *Paradoxo de Jevons*, segundo o qual ganhos de eficiência podem levar ao aumento do uso de recursos.

Estimo o impacto da recuperação de pastagens de forma desagregada nos efeitos Borlaug e Jevons, bem como seu resultado líquido. O **Efeito Borlaug** é isolado ao estimar o impacto contrafactual do aumento da qualidade das pastagens exclusivamente através da margem extensiva, sem considerar os impactos indiretos da margem intensiva. Isso representa a redução máxima possível da conversão de terras caso apenas os efeitos de economia de terra da recuperação de pastagens estivessem em jogo. Já o **Efeito Jevons** é calculado como a diferença entre o efeito Borlaug e o impacto líquido das políticas de recuperação de pastagens. Ele equivale a computar apenas o impacto indireto de  $\gamma_{pasture}$  via  $\delta$ .

Essa decomposição é ilustrada na Figura 1, que mostra como os efeitos Borlaug e Jevons evoluem à medida que o limite mínimo de participação de pastagens de alta qualidade imposto pela política aumenta. Além disso, o Apêndice D.5 apresenta uma análise semelhante, focada na decomposição do potencial de abatimento de carbono sob esses cenários de política.

Os resultados indicam que uma política hipotética que alcançasse a recuperação com-

Figure 1: Pasture recovery counterfactual



Esta figura mostra a conversão de terra potencialmente evitada em um cenário contrafactual de recuperação de pastagens. O eixo X representa a participação mínima de pastagens de alta qualidade definida pela política em cada município. O eixo Y mostra a conversão evitada em relação ao cenário de referência para cada nível de política. O painel (a) apresenta a desagregação entre os efeitos de Borlaug e Jevons, enquanto o painel (b) exibe o efeito líquido.

pleta das pastagens para alta qualidade poderia ter evitado até 23,5% da conversão de terras em pastagens observada durante o período de estudo. Esse resultado está alinhado com a hipótese de Borlaug, uma vez que melhorias na qualidade das pastagens reduzem a pressão pela expansão da terra. No entanto, um exame mais detalhado dos efeitos desagregados revela uma nuance importante. Enquanto a redução potencial máxima da conversão de terras pelo *efeito Borlaug* é estimada em 33%, aproximadamente um terço dessa redução é anulado pelo efeito oposto, o *efeito Jevons*. Em outras palavras, os incentivos à conversão impulsionados pelo aumento da produtividade da terra e dos retornos atenuam substancialmente o potencial de conservação dessa política.

### 5.3 Uso da terra carbono-eficiente

O segundo cenário contrafactual avalia o uso da terra carbono-eficiente, no qual os agentes internalizam completamente os custos externos das emissões de carbono, seguindo a abordagem de Araujo, Costa, et al. (2024). Isso é alcançado ao alinhar o valor privado percebido dos estoques de carbono ( $\alpha_b/\alpha_p$ ) com o custo social do carbono, estimado em R\$66,00 por tonelada de  $CO_2$  (Barrage et al. 2024). Conceitualmente, isso corresponde à implementação de um imposto ótimo de *first-best*, perfeitamente aplicável, sobre mudanças no uso da terra<sup>7</sup>.

<sup>7</sup>A estimativa do custo social do carbono (SCC) é um valor presente medido em dólares de 2019. Primeiro, calculo seu equivalente de anuidade com uma taxa de juros anual de 10% ( $1 - \beta$ ). Em seguida, converto para

Table 5: Summary of prevented land conversion and  $CO_2$  emissions in policy counterfactuals

Policy	Prevented Land Conversion		Prevented $CO_2$ Emissions	
	Area ( $10^4 km^2$ )	vs. Baseline (%)	Volume (Gt $CO_2$ )	vs. Baseline (%)
<b>A: Pasture Recovery</b>				
25%	0.15	3.4%	0.01	1.2%
50%	0.47	10.8%	0.07	6.0%
75%	0.81	18.7%	0.18	15.0%
100%	1.01	23.5%	0.26	21.8%
<b>B: Carbon Tax</b>				
\$0.5	1.10	25.5%	0.42	36.1%
\$1	1.81	42.0%	0.68	57.7%
\$2	2.62	60.6%	0.93	79.1%
\$5	3.46	80.1%	1.11	94.5%
\$10	3.86	89.4%	1.15	98.2%
\$20	4.09	94.8%	1.17	99.4%
\$66	4.27	98.9%	1.17	99.9%

Esta tabela apresenta os resultados para a conversão de vegetação natural em pastagem evitada e as emissões de  $CO_2$  evitadas para diferentes níveis de recuperação de pastagens e diferentes taxas de imposto sobre o carbono. As colunas (3) e (5) representam, respectivamente, as conversões evitadas e as emissões evitadas em relação às estimativas de conversão e emissão no cenário base.

Por outro lado, o aumento do valor percebido do carbono também pode ser interpretado como a valorização monetária privada de políticas ambientais mais rigorosas.


Simulo vários cenários nos quais um imposto sobre carbono é aplicado, variando de R\$0/t $CO_2$  a R\$66/t $CO_2$ , o valor no qual a eficiência de carbono é alcançada. Os resultados são resumidos no Painel B da Tabela 5. No cenário de eficiência de carbono, 98,9% da conversão de terras prevista e 99,9% das emissões de carbono teriam sido evitadas. Notavelmente, o impacto do imposto sobre carbono é altamente convexo. Embora a preservação total exija a imposição de custos elevados, a maior parte da conservação da terra e da mitigação de emissões de carbono é alcançada com níveis de imposto relativamente modestos. Por exemplo, com um imposto de carbono de apenas R\$10/ton, 89% da conversão de terras e 98% das emissões de carbono seriam evitadas. Esses resultados são ilustrados na Figura 2, que destaca a relação convexa entre a taxa de imposto e as reduções na conversão de terras e emissões. Esse padrão é altamente consistente com as descobertas de Araujo, Costa, et al. (2024) para a Amazônia.

### 5.4 Comparação

Nesta seção, comparo os impactos potenciais das duas políticas contrafactuais: recuperação de pastagens e uso da terra eficiente em carbono. A Figura 3 fornece uma comparação visual

reais usando a taxa de câmbio média de 2019, R\$3,9445 por dólar. Finalmente, atualizo para reais de 2022 utilizando o Índice de Preços ao Consumidor Amplo (IPCA).

Figure 2: Carbon taxes counterfactual




Esta figura mostra o impacto de diferentes níveis de taxa  o de carbono na convers  o de terras evitada e nas emiss  es de carbono. No painel (a), o eixo X representa a  rea com vegeta  o natural, em 10<sup>4</sup>km<sup>2</sup> (milh es de hectares), enquanto no painel (b), o eixo X representa as emiss  es de CO<sub>2</sub>. Em ambos os pain is, o eixo Y indica a taxa de imposto, em \$/tCO<sub>2</sub>.

da  rea total convertida em cada cen rio de pol tica. O painel esquerdo ilustra os resultados de uma pol tica de recupera  o de pastagens, onde as taxas de recupera  o variam de 0% a 100%. O painel direito apresenta os efeitos de uma pol tica de taxa  o de carbono, variando de R\$0 a R\$5/tCO<sub>2</sub>, ponto em que 80% das convers  es de terra j  s o evitadas.

A compara  o revela que os impostos sobre o carbono s o significativamente mais eficazes na preven  o da convers  o de terras. A redu  o m xima alcan ada por meio de uma pol tica de recupera  o de pastagens atinge um limite de 23,5%, mesmo na recupera  o total (100% de pastagens de alta qualidade). Em contraste, esse n vel de convers  o evitada   alcan ado com um imposto sobre carbono inferior a R\$1/tCO<sub>2</sub>. Essa diferen a marcante destaca a maior efici ncia dos impostos sobre o carbono em alinhar os incentivos privados com os resultados socialmente  timos para o uso da terra.

Esses achados ressaltam as limita  es relativas das pol ticas que visam apenas melhorias na produtividade. Embora a recupera  o de pastagens possa mitigar algumas press es sobre o uso da terra, ela est  sujeita a retornos decrescentes e a incentivos econ micos concorrentes, como os capturados pelo *efeito Jevons*. Em contraste, os impostos sobre o carbono internalizam diretamente o custo externo das emiss  es, tornando-os uma ferramenta muito mais potente para enfrentar o desmatamento e as emiss  es de carbono associadas.

Figure 3: Counterfactual comparison



Esta figura apresenta uma comparação dos dois cenários contrafactuais analisados. O eixo Y representa a área total convertida, em  $10^4 km^2$  (milhões de hectares). O painel (a) mostra os resultados de uma política de recuperação de pastagens, com o eixo X variando entre 0% e 100% de recuperação. O painel (b) apresenta o impacto de uma política de taxação de carbono, com o eixo X variando de \$0 a \$5/tCO<sub>2</sub>.

## 6 Conclusão

Este artigo analisa os fatores econômicos que influenciam as decisões de uso da terra na agricultura brasileira, com foco nos impactos das melhorias de produtividade agrícola e da eficiência de carbono sobre o desmatamento e as emissões de carbono. Utilizando um modelo estrutural dinâmico, exploro tanto as margens intensiva quanto extensiva das decisões de uso da terra, esclarecendo os incentivos econômicos por trás da conversão de terras e a interação entre ganhos de produtividade e a valoração do carbono.

O modelo estrutural desenvolvido neste estudo captura o comportamento prospectivo, os custos convexos e os efeitos concorrentes das melhorias de produtividade. Em particular, analiso o canal de aumento de produtividade proporcionado pela recuperação de pastagens. Por um lado, a maior qualidade das pastagens eleva os custos de conversão, reduzindo o desmatamento — uma dinâmica consistente com a hipótese de Borlaug. Por outro lado, as melhorias de produtividade também aumentam a rentabilidade da terra, incentivando uma maior conversão — um mecanismo que reflete o paradoxo de Jevons.

Os resultados da estimação do modelo também indicam que os produtores atribuem pouco ou nenhum valor monetário implícito aos estoques de carbono, ressaltando a ausência de incentivos privados para a conservação do carbono. Esse achado sugere uma lacuna significativa entre os incentivos privados para o uso da terra e os resultados socialmente ótimos, dado o custo externo das emissões de carbono.

Realizei duas análises contrafactuais. Primeiro, uma política de recuperação de pastagens, com o objetivo de aumentar a proporção de pastagens de alta qualidade nos municípios. Os resultados mostraram que a recuperação total poderia evitar até 23,5% da conversão de terras durante o período do estudo. No entanto, uma análise desagregada revelou que um terço da redução potencial do efeito Borlaug foi compensado pelo efeito oposto de Jevons. Isso demonstra que, embora políticas voltadas para a produtividade possam reduzir o desmatamento, seu potencial de economia de terra é significativamente atenuado pelo aumento dos retornos econômicos da conversão de terras.

Em seguida, examinei os impactos de uma política de uso eficiente do carbono, na qual os agentes internalizam o custo social das emissões de carbono por meio de um imposto sobre carbono. Os resultados mostram que um imposto de R\$66/tCO<sub>2</sub> — equivalente à estimativa do custo social do carbono — poderia evitar 98,9% da conversão de terras e 99,9% das emissões. Além disso, o impacto do imposto é altamente convexo: a maior parte dos benefícios de conservação e redução de emissões pode ser alcançada com uma alíquota baixa de R\$10/tCO<sub>2</sub>.

A comparação entre as duas políticas destaca a superior eficácia dos impostos sobre o carbono na contenção da conversão de terras e das emissões. Embora o impacto máximo da recuperação de pastagens seja significativo, ele equivale ao efeito de um imposto sobre o carbono inferior a R\$1/tCO<sub>2</sub>. Isso demonstra que políticas que abordam diretamente as emissões de carbono, como a precificação do carbono, são muito mais eficazes e eficientes para alcançar objetivos ambientais.

Esses resultados têm importantes implicações para o desenho de políticas públicas. Primeiro, políticas que visam melhorar a produtividade, embora benéficas para a redução do desmatamento sob certas condições, são limitadas por incentivos econômicos concorrentes. Segundo, a precificação do carbono oferece um mecanismo direto para alinhar os incentivos privados com os objetivos de bem-estar social, constituindo uma ferramenta altamente eficaz para a gestão sustentável do uso da terra. Por fim, a convexidade do impacto do imposto sugere que benefícios ambientais significativos podem ser obtidos a um custo relativamente baixo, tornando a precificação do carbono uma solução politicamente e economicamente viável.

## References

- Abatzoglou, J. T. et al. (2018). “TerraClimate, a high-resolution global dataset of monthly climate and climatic water balance from 1958–2015”. en. In: *Scientific Data* 5.1.
- Abman, R. et al. (2024). *Agricultural Productivity and Deforestation*. en.
- Aguirregabiria, V. et al. (2002). “Swapping the Nested Fixed Point Algorithm: A Class of Estimators for Discrete Markov Decision Models”. In: *Econometrica* 70.4.
- (2007). “Sequential Estimation of Dynamic Discrete Games”. en. In: *Econometrica* 75.1.
- (2010). “Dynamic discrete choice structural models: A survey”. en. In: *Journal of Econometrics* 156.1.

- Angrist, J. D. et al. (2001). "Instrumental Variables and the Search for Identification: From Supply and Demand to Natural Experiments". en. In: *Journal of Economic Perspectives* 15.4.
- Arantes, A. E. et al. (2018). "Livestock intensification potential in Brazil based on agricultural census and satellite data analysis". en. In: *Pesquisa Agropecuária Brasileira* 53.9.
- Araujo, R., J. Assunção, et al. (2023). *The Effects of Transportation Infrastructure on Deforestation in the Amazon: A General Equilibrium Approach*. en.
- Araujo, R., F. J. M. Costa, et al. (2020). *Efficient Forestation in the Brazilian Amazon*. en. preprint.
- (2024). *Efficient Conservation of the Brazilian Amazon: Estimates from a Dynamic Model*. en.
- Arcidiacono, P. and P. B. Ellickson (2011). "Practical Methods for Estimation of Dynamic Discrete Choice Models". en. In: *Annual Review of Economics* 3.1.
- Arcidiacono, P. and R. A. Miller (2011). "Conditional Choice Probability Estimation of Dynamic Discrete Choice Models with Unobserved Heterogeneity". In: *Econometrica* 79.6.
- Baccini, A. et al. (2012). "Estimated carbon dioxide emissions from tropical deforestation improved by carbon-density maps". en. In: *Nature Climate Change* 2.3.
- Balboni, C. et al. (2023). "The Economics of Tropical Deforestation". In: *Annual Review of Economics* 15.1.
- Barrage, L. et al. (2024). "Policies, projections, and the social cost of carbon: Results from the DICE-2023 model". en. In: *Proceedings of the National Academy of Sciences* 121.13.
- Barrozo, M. (2024). "Market Power and Carbon Emissions in the Amazon". en. In.
- Borusyak, K. et al. (2022). "Quasi-Experimental Shift-Share Research Designs". In: *The Review of Economic Studies* 89.1.
- Brazil (2023). *Decreto No. 11.815. Institui o Programa Nacional de Conversão de Pastagens Degradadas em Sistemas de Produção Agropecuários e Florestais Sustentáveis e o seu Comitê Gestor Interministerial*.
- Bustamante, M. M. C. et al. (2012). "Estimating greenhouse gas emissions from cattle raising in Brazil". en. In: *Climatic Change* 115.3.
- Calil, Y. C. D. et al. (2019). "Brazil's Agricultural Production and Its Potential as Global Food Supplier". en. In.
- Carlos, S. D. M. et al. (2022). *Custos Da Recuperação De Pastagens Degradadas Nos Estados E Biomas Brasileiros*. pt. Tech. rep. FGV EESP.
- Carreira, I. et al. (2024). "The deforestation effects of trade and agricultural productivity in Brazil". en. In: *Journal of Development Economics* 167.
- Cerri, C. E. P. et al. (2018). "Reducing Amazon Deforestation through Agricultural Intensification in the Cerrado for Advancing Food Security and Mitigating Climate Change". en. In: *Sustainability* 10.4.
- Chomitz, K. M. et al. (1996). "Roads, Land Use, and Deforestation: A Spatial Model Applied to Belize". In: *The World Bank Economic Review* 10.3.
- Clima, O. do (2023). *Análise das emissões de gases de efeito estufa e suas implicações para as metas climáticas do Brasil: 1970-2022*. pt. Tech. rep. 11. Observatório do Clima.



- Desbureaux, S. et al. (2018). "Rain, forests and farmers: Evidence of drought induced deforestation in Madagascar and its consequences for biodiversity conservation". In: *Biological Conservation* 221.
- Dias-Filho, M. B. (2012). "Desafios da Produção Animal em Pastagens na Fronteira Agrícola Brasileira". pt. In: *Documentos Embrapa Amazônia Oriental* 382.
- (2014). "Diagnóstico das Pastagens no Brasil". pt. In: *Documentos Embrapa Amazônia Oriental* 402.
- (2015). "Estratégias de recuperação de pastagens degradadas na Amazônia brasileira." por. In: *Documentos Embrapa Amazônia Oriental* 411.
- Ehrl, P. (2017). "Minimum comparable areas for the period 1872-2010: an aggregation of Brazilian municipalities". pt. In: *Estudos Econômicos (São Paulo)* 47.
- FAO, ed. (2017). *The future of food and agriculture: trends and challenges*. en. Rome: Food and Agriculture Organization of the United Nations.
- Feltran-Barbieri, R. et al. (2021). "Degraded pastures in Brazil: improving livestock production and forest restoration". en. In: *Royal Society Open Science* 8.7.
- Gaulier, G. et al. (2010). "BACI: International Trade Database at the Product-Level (the 1994-2007 Version)". en. In: *SSRN Electronic Journal*.
- Goel, S. (2020). *Impact of Beef Prices on Deforestation in the Amazon*. en.
- Hall, R. E. (1978). "Stochastic Implications of the Life Cycle-Permanent Income Hypothesis: Theory and Evidence". In: *Journal of Political Economy* 86.6.
- Harris, N. L. et al. (2021). "Global maps of twenty-first century forest carbon fluxes". en. In: *Nature Climate Change* 11.3.
- Hess, S. et al. (2021). "Environmental effects of development programs: Experimental evidence from West African dryland forests". en. In: *Journal of Development Economics* 153.
- Hotz, V. J. et al. (1993). "Conditional Choice Probabilities and the Estimation of Dynamic Models". en. In: *The Review of Economic Studies* 60.3.
- Hsiao, A. (2024). *Coordination and Commitment in International Climate Action*. en.
- IBGE (2024). *Bioma Predominante Por Município Para Fins Estatísticos*.
- Jarvis, L. S. (1974). "Cattle as Capital Goods and Ranchers as Portfolio Managers: An Application to the Argentine Cattle Sector". en. In: *Journal of Political Economy*.
- Jayachandran, S. (2022). "How Economic Development Influences the Environment". en. In: *Annual Review of Economics* 14. Volume 14, 2022.
- Kaimowitz, D. et al. (1998). "Economic Models of Tropical Deforestation A Review". en. In.
- Lapig, L. d. P. d. I. e. G. et al. (2023). *Mapeamentos de pastagem na Amazônia*. NOta Técnica 1/2023/LAPIG/INPE/EMBRAPA. Goiânia.
- Magnac, T. et al. (2002). "Identifying Dynamic Discrete Decision Processes". en. In: *Econometrica* 70.2,
- Müller-Hansen, F. et al. (2019). "Can Intensification of Cattle Ranching Reduce Deforestation in the Amazon? Insights From an Agent-based Social-Ecological Model". en. In: *Ecological Economics* 159.

- Pacheco, P. L. S. (2021). "Crops substitution and climate change: estimating farmers decisions". pt. In.
- Pagel, J. (2022). "Aid Against Trees? Evidence from a Community-Driven Development Program in the Philippines". en. In: *SSRN Electronic Journal*.
- Pfaff, A. S. (1999). "What Drives Deforestation in the Brazilian Amazon?" en. In: *Journal of Environmental Economics and Management* 37.1.
- Pimentel, D. A. (2021). "Livestock intensification and deforestation: Evidences from the Brazilian cerrado". pt. In.
- Rosen, S. (1987). "Dynamic Animal Economics". en. In: *American Journal of Agricultural Economics* 69.3.
- Rosen, S. et al. (1994). "Cattle Cycles". en. In: *Journal of Political Economy* 102.3.
- Rust, J. (1987). "Optimal Replacement of GMC Bus Engines: An Empirical Model of Harold Zurcher". In: *Econometrica* 55.5.
- Santos, C. O. d. et al. (2022). "Assessing the Wall-to-Wall Spatial and Qualitative Dynamics of the Brazilian Pasturelands 2010–2018, Based on the Analysis of the Landsat Data Archive". en. In: *Remote Sensing* 14.4.
- Scott, P. T. (2014). "Dynamic Discrete Choice Estimation of Agricultural Land Use". en. In.
- Skidmore, M. E. (2023). "Outsourcing the dry season: Cattle ranchers' responses to weather shocks in the Brazilian Amazon". en. In: *American Journal of Agricultural Economics* 105.2.
- Souza, C. M. et al. (2020). "Reconstructing Three Decades of Land Use and Land Cover Changes in Brazilian Biomes with Landsat Archive and Earth Engine". en. In: *Remote Sensing* 12.17.
- Souza-Rodrigues, E. (2019). "Deforestation in the Amazon: A Unified Framework for Estimation and Policy Analysis". In: *The Review of Economic Studies* 86.6 (311).
- Stokey, N. L. et al. (1989). *Recursive methods in economic dynamics*. Cambridge, Mass: Harvard University Press.
- Strassburg, B. B. et al. (2014). "When enough should be enough: Improving the use of current agricultural lands could meet production demands and spare natural habitats in Brazil". en. In: *Global Environmental Change* 28.
- Szerman, D. et al. (2022). "Agricultural Productivity and Deforestation: Evidence from Brazil". en. In.
- Velthuisen, H. van et al. (2007). *Mapping biophysical factors that influence agricultural production and rural vulnerability*. en. Tech. rep.

## Apêndices

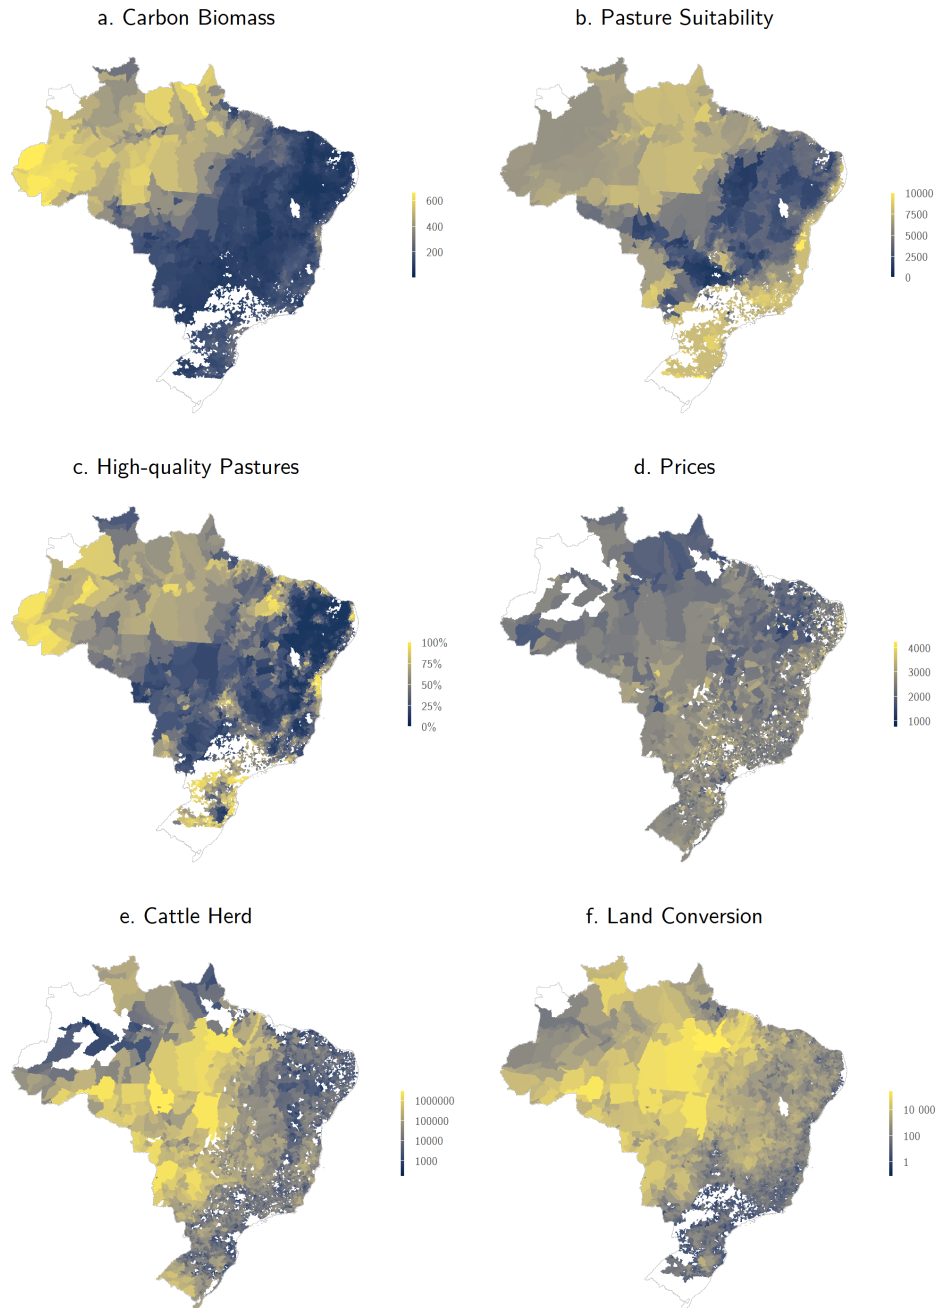
Os apêndices estão organizados da seguinte forma:

- A.** Descrição dos dados empregados: Apresenta uma visão detalhada das fontes de dados utilizadas no estudo, incluindo variáveis-chave, unidades de observação e métodos de processamento aplicados para garantir a consistência e a qualidade dos dados.

- B.** Detalhes sobre a degradação das pastagens: Discute a metodologia empregada para classificar e medir a degradação das pastagens, bem como a relevância desse fenômeno para a modelagem econômica do uso da terra.
- C.** Detalhes técnicos: Fornece um aprofundamento matemático e metodológico dos principais aspectos do modelo econômico desenvolvido no estudo.
  - A.1** Derivação da condição de optimalidade da margem intensiva: Apresenta a formulação teórica da decisão ótima do produtor na margem intensiva, levando em conta custos e benefícios do uso da terra.
  - A.2** Derivação da condição de optimalidade da margem extensiva: Expõe a formulação da decisão ótima na margem extensiva, considerando os incentivos à conversão de novas áreas de vegetação natural em uso agropecuário.
  - A.3** Descrição detalhada dos instrumentos empregados: Explica os instrumentos econométricos utilizados para estimar os efeitos causais e corrigir possíveis problemas de endogeneidade nos modelos empíricos.
- D.** Exercícios empíricos adicionais: Apresenta análises complementares que reforçam a robustez dos resultados principais do estudo.
  - D.1** Margem intensiva: resultados da primeira etapa: Exibe os resultados da estimação da primeira etapa para a margem intensiva, avaliando a relação entre produtividade e decisões de uso da terra.
  - D.2** Margem intensiva com efeitos fixos municipais: Examina os impactos da inclusão de efeitos fixos municipais na estimação da margem intensiva, controlando para características locais não observadas.
  - D.3** Margem extensiva: resultados da primeira etapa: Apresenta os resultados da primeira etapa da estimação para a margem extensiva, explorando os determinantes da conversão de terras.
  - D.4** Exercício da margem extensiva com dados de pesquisa: Realiza uma análise empírica adicional utilizando dados de pesquisa específicos para validar os achados do estudo.
  - D.5** Efeito da recuperação de pastagens na redução de emissões: Avalia o impacto da recuperação de pastagens sobre a mitigação das emissões de carbono, quantificando o potencial de políticas voltadas para o manejo sustentável do solo.

## A Descrição dos dados

Figure 4: Geographical Distribution of Main Variables



This figure plots for each municipality in sample, **(a)** the carbon biomass density, measured in tons of  $CO_2$  per hectare; **(b)** the index of pasture suitability from FAO-GAEZ; **(c)** the share of pastures with high quality, in 2017; **(d)** the average per capita price of cattle sold for slaughter in 2017, measured in R\$ of 2022; **(e)** the herd of cattle at the end of 2017; **(f)** total area converted from natural vegetation to pasture in 2006 and 2007, measured in hectares.

## A.1 Municipalities

The number and area of municipalities – the smallest administrative divisions in Brazil – change over time due to the creation of new municipalities or the annexation of existing ones. To address this issue, I use the concept of *minimum comparable areas* (AMCs), which are time-consistent regions enabling the construction of municipality panel data. I follow the methodology of Ehrl (2017), who developed AMCs for the period 1872–2010, and extend it to account for municipal boundary changes between 2010 and 2022.

All official statistics at the municipality level are aggregated to the AMC level. Additionally, I calculate the predominant biome in each AMC, defined as the biome occupying the largest share of its area, based on the methodology from IBGE (2024). Hereafter, I refer to these minimum comparable areas simply as municipalities.

## A.2 Cattle herd

I use two data sources to estimate the herd of cattle per municipality per year. The primary source is the *Agricultural Census* from the Brazilian Institute of Geography and Statistics (IBGE) for the years 1995, 2006, and 2017. The census collects detailed data on agricultural establishments and their activities, with each production unit serving as the observation unit. The second source is the annual livestock production surveys (*Pesquisa da Pecuária Municipal*, from IBGE). This dataset is primarily derived from administrative records of the Foot-and-Mouth Disease Vaccination Campaigns<sup>8</sup>, compiled by state and local inspectorates as well as veterinary posts.

To approximate  $h_{mt}$ , which is a theoretical measure of livestock per plot of land, I normalize the municipality's head of cattle by its total area. This normalization ensures a temporally and spatially consistent measure of livestock density across municipalities of varying sizes. It then facilitates cross-sectional and temporal comparisons, as it accounts for differences in land availability that could otherwise confound the relationship between herd size and other variables of interest.

## A.3 Cattle prices

I derive local cattle prices from sales and revenue data obtained in the 2006 and 2017 administrations of *Agricultural Census*. These represent the cattle price per animal sold for slaughter in each municipality. To project prices for the subsequent year, I adjust them using variations in a national cattle price index. This variation is computed by comparing the average index in the census year with the average for the 12 months following the census.

The cattle price index, sourced from the *Center for Advanced Studies in Applied Economics* (CEPEA), measures the average price of 15 kg of carcass weight at slaughter for finished bull sales in São Paulo State. São Paulo prices are industry benchmarks; less productive regions

---

<sup>8</sup>Campanha de Vacinação contra a Febre Aftosa

typically have lower prices but exhibit similar trends. All prices are deflated to December 2022 values using the Extended National Consumer Price Index (IPCA).

## A.4 Land use

Land-use data is sourced from the *MapBiomass Project* (Souza et al. 2020), which provides annual 30-meter resolution maps derived from Landsat imagery. Using a random forest classifier, spatial-temporal filters to minimize noise, and thorough accuracy assessments, MapBiomass classifies each pixel into predefined land-use categories. Year-on-year transition matrices are created by comparing pixel classifications between consecutive years, enabling detailed tracking of land-use changes over time.

I aggregate land-use statistics and transitions into four categories: agriculture, pasture, natural vegetation, and other (e.g., non-classified pixels, urban areas, and water). My analysis focuses on transitions from natural vegetation to pasture. The conditional choice probabilities  $\rho_{mt}$  are estimated non-parametrically as the share of natural vegetation pixels converted to pasture in each municipality for each pair of successive years.

## A.5 Pasture quality

For this study, I use high-resolution data on the quality of Brazilian pastures developed as part of the *MapBiomass Project* (Santos et al. 2022). This dataset is constructed based on the Normalized Difference Vegetation Index (NDVI), a widely used metric for assessing vegetation health and productivity. The NDVI is derived by comparing the reflectance of electromagnetic radiation in the red and near-infrared portions of the spectrum, utilising imagery from Landsat satellites. It serves as an effective proxy for vegetative vigour, with higher values generally indicating healthier, more productive vegetation.

Pasture quality is inherently influenced by local environmental conditions, meaning that a pasture considered degraded in one biome might still perform adequately in another (Dias-Filho 2014). To account for this geographical heterogeneity, the dataset normalizes the median NDVI values using biome-specific maximum and minimum percentiles. This normalization ensures that comparisons are made relative to the optimal vegetation conditions within each biome. After normalization, the NDVI values are categorised into three classes of vegetative vigour, corresponding to the states of high, medium and low vigour.

The use of NDVI as an indicator of pasture quality is grounded in its ability to reflect biological degradation by capturing the health of vegetation and its forage productivity. However, this measure is less effective at detecting agricultural degradation, which involves increased weed presence that competes pastures out (Lapig et al. 2023). As such, while the data is highly suited to assessing the biological quality of pastures, it may underestimate the full extent of degradation in areas where agricultural degradation is more prevalent.

By employing this dataset, my analysis focuses on the counterfactual scenarios of improving the *biological* quality of pastures. For a broader discussion on the distinctions between

biological and agricultural degradation, as well as the causes and consequences of pasture degradation, see Appendix B.

To construct an indicator of pasture quality for each municipality, I calculate the share of its pasture area classified with high vegetative vigour. This approach offers the advantage of producing a continuous variable, which provides greater granularity in capturing variations in pasture quality across municipalities and over time. By focusing on the share of high-vigour pastures, the measure inherently accounts for the quality of all remaining pasture areas, implicitly classifying those with lower vigour as degraded. This includes areas identified as either mildly or severely degraded based on their vegetative state.

This indicator offers a more flexible metric for evaluating policy changes in pasture quality and their potential impacts compared to a categorical variable. In counterfactual scenarios, it enables the assessment of gradual increases in the share of high-quality pastures. These improvements represent a hypothetical recovery or restoration of degraded pasture areas, encompassing the entire spectrum of degradation, from mild to severe.

## A.6 International trade

To address endogeneity concerns in price determination, I use exogenous demand shocks derived from trends in Chinese agricultural imports as instrumental variables. These shocks represent external demand variations that are independent of local supply conditions. Specifically, I construct a shift-share instrumental variable that allocates aggregate demand shocks from China to Brazilian municipalities in proportion to their respective market shares. This approach allows me to isolate exogenous variation in local prices that stems from global market conditions.

The trade data for constructing this instrument come from the *CEPII BACI - International Trade Database at the Product-Level* (Gaulier et al. 2010). The BACI dataset provides detailed bilateral trade flows between more than 200 countries and covers approximately 5,000 products classified using the Harmonized System (6-digit codes). The dataset spans the period 1995 – 2022, and I align my analysis with the broader China-shock literature by using 2000 as the base year, reflecting China's accession to the World Trade Organization (WTO) in 2001.

## A.7 Aboveground carbon biomass

In the model, the returns to maintaining fields as natural vegetation depend on their above-ground carbon biomass. For this, I rely on high-resolution (30-meter) spatial data of Above-ground Live Woody Biomass (AGB), measured in megagrams per hectare for the year 2000. This data was developed by Harris et al. (2021), based on the methodology developed by Baccini et al. (2012). The authors integrate ground-based biomass measurements from over 700,000 sample locations with satellite imagery from Landsat, processed through a machine-learning predictive model.

Finally, I convert the biomass weight provided in the dataset to the potential of CO<sub>2</sub> release, accounting for the molecular weight of carbon dioxide, following Araujo, Costa, et al. (2020). To



convert aboveground biomass to potential CO<sub>2</sub> release, I first divide the weight by 2 to estimate the carbon content, as biomass is roughly 50% carbon. Then, I multiply this carbon content by the ratio of the molecular weights of CO<sub>2</sub> (44) to carbon (12), which converts the carbon content into the equivalent amount of carbon dioxide. This conversion enables direct comparison with international estimations of the social cost of carbon.

## **A.8 Weather controls**

For weather controls, I utilize data from the *TerraClimate* dataset, which offers global high-resolution monthly climate and water balance data (Abatzoglou et al. 2018). TerraClimate integrates climatological normals with time-varying data to produce comprehensive monthly estimates. I include data on minimum, mean, and maximum temperatures, as well as the Palmer Drought Severity Index (PDSI), a standardized measure of long-term moisture availability that accounts for precipitation, evapotranspiration, and soil water balance. The PDSI is particularly relevant for its impact on pasture quality, as it reflects the availability of water for plant growth, with drought conditions leading to reduced forage productivity and quality.

## **A.9 Transportation cost and market access**

To control for the effects of transportation infrastructure on deforestation, I use quality-adjusted transportation cost estimates and a measure of market access to other regions (Araujo, Assunção, et al. 2023; Araujo, Costa, et al. 2024). These metrics are based on detailed geographical data on roads, waterways, railways, and ports. They estimate the cost of transporting goods to international markets and quantify a municipality's connectivity to other regions. The market access measure is derived from an inter-regional trade model that incorporates population distribution and trade elasticity.

## **A.10 Pasture suitability**

To account for biophysical factors influencing agricultural productivity, I use a pasture suitability index developed by the *Food and Agriculture Organization's (FAO) Global Agro-Ecological Zones project* (Velthuisen et al. 2007). This index integrates multiple dimensions of climate, soil, and terrain characteristics to estimate attainable productivity for pasture, providing a score from 0 to 10000. The climate factors include thermal conditions, the length of the growing period, climate variability, and limitations such as cold temperatures or insufficient moisture. Soil characteristics, such as depth, type, and quality, are also considered, along with terrain features like slope. With it, I can control for several environmental determinants of pasture productivity at once.

## B Details on pasture degradation

Pasture degradation refers to the decline in a pasture's capacity to support livestock. This phenomenon is characterised by a progressive loss of pasture vigour and resilience, impairing its ability to recover after grazing or adverse environmental conditions. As a result, pasture degradation poses a significant challenge to the sustainability of livestock production systems. Pasture degradation can be broadly categorised into two main types: agricultural degradation and biological degradation (Dias-Filho [2014](#)).

Agricultural degradation is primarily associated with the encroachment of invasive plant species and the proliferation of weeds. These competing plants reduce the availability of high-quality forage for livestock, making grazing increasingly inefficient. Over time, the dominance of weeds further suppresses pasture productivity, creating a feedback loop of reduced forage availability, decreased livestock performance, and declining agricultural output.

Biological degradation, in contrast, arises from soil deterioration. It manifests as a reduction in vegetation cover, leading to soil erosion, loss of organic matter, and the depletion of critical nutrients needed to sustain plant growth. This form of degradation is more severe than agricultural degradation because it undermines the fundamental capacity of the soil to support any vegetation, further exacerbating environmental and productivity challenges.

The drivers of degradation include a combination of improper grazing practices and external environmental factors. Inadequate grazing management – such as overgrazing, poor rest period planning, neglect of soil fertility restoration, and excessive reliance on fire – contributes significantly to both agricultural and biological degradation. Additionally, factors like pest infestations, plant diseases, and adverse environmental conditions (e.g., low rainfall or poor soil fertility) amplify the degradation process.

Recovery efforts typically involve interventions such as soil fertility restoration, reseeding with high-quality forage species, and implementing rotational grazing systems. These measures not only address the symptoms of degradation but also tackle its root causes, including improper grazing management and nutrient imbalances (Dias-Filho [2015](#)).

In Brazil, pasture degradation remains a pervasive issue, affecting both the environmental health of grazing lands and the economic viability of livestock farming. Although recent improvements have been documented, degraded pastures still constitute a substantial share of total pastureland. For instance, in 2018, 58.9% of pastures in Brazil exhibited some level of degradation (Santos et al. [2022](#)).

The recovery of degraded pastures is often presented in the literature as a key component of agricultural intensification strategies, with the potential to enhance productivity while reducing pressure on natural ecosystems. By improving the productive capacity of existing pastures, some argue that pasture recovery could discourage the need for additional land conversion and thus help curb deforestation (Carlos et al. [2022](#); Dias-Filho [2012](#); Feltran-Barbieri et al. [2021](#)).

However, while this premise is widely cited, it remains largely untested in the context of comprehensive economic models of land use. As demonstrated in this paper, the interplay be-

tween pasture quality and land conversion is complex. While higher-quality pastures can indeed reduce deforestation through increased conversion costs (the Borlaug effect), the associated productivity gains may simultaneously incentivise land conversion by raising the economic returns to grazing (the Jevons effect). These countervailing forces suggest that the potential of pasture recovery as a deforestation mitigation strategy must be carefully scrutinised, particularly in policy discussions aimed at achieving sustainable agricultural development.

## C Demonstrations

### C.1 Intensive Margin

#### C.1.1 Derivation of the optimality condition

The first order condition states that, at the optimum, marginal revenue equals the discounted future marginal value of the herd.

$$\begin{aligned}\frac{\partial r(c_{it}; \mathbf{s}_{mt})}{\partial c_{it}} &= -\beta \mathbb{E}_t \left[ \frac{\partial \mathcal{V}(h_{it+1}; \mathbf{s}_{mt+1})}{\partial h_{it+1}} \frac{\partial h_{it+1}}{\partial c_{it}} \right] \\ &= \beta \mathbb{E}_t \left[ \frac{\partial \mathcal{V}(h_{it+1}; \cdot)}{\partial h_{it+1}} \right]\end{aligned}\tag{9}$$

And by the envelope theorem, at the optimum, the marginal value equals the discounted future marginal value, increased by  $\phi$ , minus marginal costs.

$$\begin{aligned}\frac{\partial \mathcal{V}(h_{it}; \mathbf{s}_{mt})}{\partial h_{it}} &= -\frac{\partial \psi(h_{it}; \mathbf{s}_{mt})}{\partial h_{it}} + \beta \mathbb{E}_t \left[ \frac{\partial \mathcal{V}(h_{it+1}; \mathbf{s}_{mt+1})}{\partial h_{it+1}} \frac{\partial h_{it+1}}{\partial h_{it}} \right] \\ &= -\frac{\partial \psi(h_{it}; \cdot)}{\partial h_{it}} + \beta(1 + \phi) \mathbb{E}_t \left[ \frac{\partial \mathcal{V}(h_{it+1}; \cdot)}{\partial h_{it+1}} \right]\end{aligned}\tag{10}$$

Substituting 9 in 10 yields:

$$\frac{\partial \mathcal{V}(h_{it}; \cdot)}{\partial h_{it}} = -\frac{\partial \psi(h_{it}; \cdot)}{\partial h_{it}} + (1 + \phi) \frac{\partial r(c_{it}; \cdot)}{\partial c_{it}}$$

Forwarding it one period, and substituting back into 9, we reach the optimality condition of the problem, given by the following Euler equation:

$$\frac{\partial r(c_{it}; \cdot)}{\partial c_{it}} = \beta \mathbb{E}_t \left[ (1 + \phi) \frac{\partial r(c_{it+1}; \cdot)}{\partial c_{it+1}} - \frac{\partial \psi(h_{it+1}; \cdot)}{\partial h_{it+1}} \right]\tag{11}$$

That means optimal slaughter  $c_{it}$  is that which equates marginal revenue from a sale at  $t$  to the discounted expected marginal opportunity cost of the forgone sale at  $t + 1$ . Each new animal sold increases revenues at  $t$ , but reduces the herd for the next period, reducing potential revenues but also reducing the herd carrying cost.

Note that for every plot  $i$  in municipality  $m$ , the farmers face the same optimality condition. Therefore, I can denote the optimal choice  $h_{it}^*$  for every plot in municipality  $m$  as simply  $h_{mt}$ . From the specified functional forms, marginal revenues and costs are given by:

$$\begin{aligned}\frac{\partial r(c_{it}; \cdot)}{\partial c_{it}} &= \alpha_p p_{mt} \\ \frac{\partial r(c_{it+1}; \cdot)}{\partial c_{it+1}} &= \alpha_p p_{mt+1} \\ \frac{\partial \psi(h_{mt+1}; \cdot)}{\partial h_{mt+1}} &= \delta h_{mt+1} + \mathbf{x}_{it+1} \gamma_x + \gamma_g + \gamma_t(t+1) + \varepsilon_{it+1}\end{aligned}$$

With this, I can write the Euler equation 11 as follows.

$$\frac{1}{\beta} \alpha_p p_{mt} = \alpha_p (1 + \phi) \mathbb{E}_t[p_{mt+1}] - \mathbb{E}_t[\delta h_{mt+1} + \mathbf{x}_{it+1} \gamma_x + \gamma_g + \gamma_t(t+1) + \varepsilon_{it+1}] \quad (12)$$

Note that, from the law of motion, the process of deciding on  $c_{it}$  at period  $t$  also defines  $h_{mt+1}$ . Hence, I can write  $\mathbb{E}_t[h_{mt+1}] = h_{mt+1}$ .

$$\delta h_{mt+1} = \alpha_p (1 + \phi) \mathbb{E}_t[p_{mt+1}] - \frac{1}{\beta} \alpha_p p_{mt} - \mathbb{E}_t[\mathbf{x}_{it+1} \gamma_x] - \gamma_g - \gamma_t(t+1) - \mathbb{E}_t[\varepsilon_{it+1}]$$

Which can be then rewritten as 2.

## C.2 Extensive Margin

### C.2.1 Derivation of the optimality condition

I further define the ex-ante value function, which is the expected value of being in state  $\mathbf{s}_{mt}$  before the realization of shocks  $\boldsymbol{\nu}_{it}$ .

$$\bar{V}(0, \mathbf{s}_{mt}) \equiv \mathbb{E}_{\boldsymbol{\nu}}[V(0, \mathbf{s}_{mt}, \boldsymbol{\nu}_{it})]$$

And the conditional value functions, which are the present value of choosing  $j$  in period  $t$  and behaving optimally afterwards. Here, consider  $\pi_{mt}(j)$  to mean the payoffs  $\pi(j, \mathbf{s}_{mt}, \boldsymbol{\nu}_{it})$  net of the idiosyncratic shocks  $\nu_{ijt}$ .

$$v(0, \mathbf{s}_{mt}) = \pi_{mt}(0) + \beta \mathbb{E}[\bar{V}(0, \mathbf{s}_{mt+1}) | \mathbf{s}_{mt}] \quad (13)$$

$$v(1, \mathbf{s}_{mt}) = \pi_{mt}(1) \quad (14)$$

Assumption 4 of EV1 extensive margin shocks implies the conditional choice probabilities have closed-form logit solutions. That is to say, the probability of observing a choice of land

conversion from forest to pastures ( $j_t = 1$ ), is given by:

$$\rho(1 \mid \mathbf{s}_{mt}) = \frac{\exp[v(1, \mathbf{s}_{mt})]}{\exp[v(0, \mathbf{s}_{mt})] + \exp[v(1, \mathbf{s}_{mt})]}$$

To lighten notation, I denote henceforth  $\rho(1 \mid \mathbf{s}_{mt}) = \rho_{mt}$  and  $\rho(0 \mid \mathbf{s}_{mt}) = 1 - \rho_{mt}$ , which follows from the binary choice set. Using the Hotz et al. (1993) inversion, I can rearrange the conditional choice probabilities and relate their ratio to the difference in conditional value functions:

$$\log\left(\frac{\rho_{mt}}{1 - \rho_{mt}}\right) = v(1, \mathbf{s}_{mt}) - v(0, \mathbf{s}_{mt}) \quad (15)$$

And applying Arcidiacono and Miller (2011)'s *Lemma 1* to the EV1 case, the ex-ante value function can be rewritten with respect to the conditional value function of any arbitrary choice:

$$\bar{V}_{it}(0) = v(1, \mathbf{s}_{mt}) - \log(\rho_{mt}) + \gamma \quad (16)$$

Where  $\gamma$  is the Euler-Mascheroni constant. In equation 15, I substitute the conditional value functions with 13 and 14, and apply equation 16 forwarded one period:

$$\begin{aligned} \log\left(\frac{\rho_{mt}}{1 - \rho_{mt}}\right) &= \pi_{mt}(1) - \pi_{mt}(0) - \beta \mathbb{E}_t[\bar{V}_{it+1}(0)] \\ &= \pi_{mt}(1) - \pi_{mt}(0) - \beta \mathbb{E}_t[\pi_{mt+1}(1) - \log(\rho_{mt+1}) + \gamma] \end{aligned}$$

Now, I open  $\pi_{mt+1}(1)$  to include the intensive margin value function.

$$\begin{aligned} \log\left(\frac{\rho_{mt}}{1 - \rho_{mt}}\right) &= -\Psi(\mathbf{s}_{mt}) + \mathcal{V}(h_{mt} = 0, \mathbf{s}_{mt}) + \xi_{mt} - \pi_{mt}(0) \\ &\quad - \beta \mathbb{E}_t[-\Psi(\mathbf{s}_{mt+1}) + \mathcal{V}(h_{mt+1} = 0, \mathbf{s}_{mt+1}) + \xi_{mt+1} - \log(\rho_{mt+1}) + \gamma] \end{aligned} \quad (17)$$

Before advancing, I first develop the following difference of intensive-margin value functions. From now on, I denote optimal decisions in the path where the plot is deforested at  $t$  using one-asterisk-variables (\*), and where it was deforested at  $t + 1$  using two-asterisk-variables (\*\*).

$$\begin{aligned} \mathcal{V}(h_{mt} = 0, \mathbf{s}_{mt}) - \beta \mathbb{E}_t[\mathcal{V}(h_{mt+1} = 0, \mathbf{s}_{mt+1})] \\ &= r(c_{it}^*; \cdot \mid h_{mt} = 0) + \beta \mathbb{E}_t[\mathcal{V}(h_{mt+1}^*; \cdot)] \\ &\quad - \beta \mathbb{E}_t[r(c_{it+1}^{**}; \cdot \mid h_{mt+1} = 0) + \beta \mathbb{E}_{t+1}[\mathcal{V}(h_{mt+2}^{**}; \cdot)]] \end{aligned}$$

And developing further:

$$\begin{aligned} \mathcal{V}(h_{mt} = 0, \mathbf{s}_{mt}) - \beta \mathbb{E}_t [\mathcal{V}(h_{mt+1} = 0, \mathbf{s}_{mt+1})] \\ = r(c_{it}^*; \cdot \mid h_{mt+1} = 0) + \beta \mathbb{E}_t \left[ r(c_{it+1}^*; \cdot) - \psi(h_{mt+1}^*; \cdot) + \beta \mathbb{E}_{t+1} [\mathcal{V}(h_{mt+2}^*; \cdot)] \right] \\ - \beta \mathbb{E}_t \left[ r(c_{it+1}^{**}; \cdot \mid h_{mt+1} = 0) + \beta \mathbb{E}_{t+1} [\mathcal{V}(h_{mt+2}^{**}; \cdot)] \right] \end{aligned}$$

The revenues  $r(c_{it+1}^*; \cdot)$  and  $r(c_{it+1}^{**}; \cdot \mid h_{mt+1} = 0)$  are not equal, because the latter comes from the initial herd allocation at  $t + 1$ . In these initial allocations, it can be shown using the law of motion that the consumptions alone define the herd that is left for the next period. That is:

$$\begin{aligned} c_{it}^* \mid h_{mt}=0 &= -h_{mt+1}^* \\ c_{it+1}^{**} \mid h_{mt+1}=0 &= -h_{mt+2}^{**} \end{aligned} \tag{18}$$

More importantly, it can be shown that  $h_{mt+2}^* = h_{mt+2}^{**}$ . It happens because the optimal choice of next-period herd follows from the intensive-margin Euler condition (equation 11) and is only forward-looking. Regardless of inherited herd, the rancher will consume optimally so that they end the period with the herd defined by the same optimality condition.

It means that, whether the rancher deforests at  $t$  or at  $t + 1$ , at the end of  $t + 1$  they have herd size  $h_{mt+2}^* = h_{mt+2}^{**}$ . It follows then, that  $\mathcal{V}(h_{mt+2}^*; \cdot) = \mathcal{V}(h_{mt+2}^{**}; \cdot)$ . That is to say, the property of finite dependence holds and I can difference out the continuation values. Therefore, we can write the difference as:

$$\begin{aligned} \mathcal{V}(h_{mt} = 0, \mathbf{s}_{mt}) - \beta \mathbb{E}_t [\mathcal{V}(h_{mt+1} = 0, \mathbf{s}_{mt+1})] \\ = r(c_{it}^*; \cdot \mid h_{mt} = 0) + \beta \mathbb{E}_t \left[ r(c_{it+1}^*; \cdot) - \psi(h_{mt+1}^*; \cdot) - r(c_{it+1}^{**}; \cdot \mid h_{mt+1} = 0) \right] \end{aligned}$$

Now we can return to the equation 17 and substitute this difference.

$$\begin{aligned} \log \left( \frac{\rho_{mt}}{1 - \rho_{mt}} \right) = -\Psi(\mathbf{s}_{mt}) + \xi_{mt} - \pi_{mt}(0) - \beta \mathbb{E}_t \left[ -\Psi(\mathbf{s}_{mt+1}) + \xi_{mt+1} - \log(\rho_{mt+1}) + \gamma \right] \\ + r(c_{it}^*; \cdot \mid h_{mt} = 0) + \beta \mathbb{E}_t \left[ r(c_{it+1}^*; \cdot) - \psi(h_{mt+1}^*; \cdot) - r(c_{it+1}^{**}; \cdot \mid h_{mt+1} = 0) \right] \end{aligned}$$

Now, using the specified functional forms for intensive margin revenues and costs(1), extensive margin payoffs (??), and the results from 18.

$$\begin{aligned} \log \left( \frac{\rho_{mt}}{1 - \rho_{mt}} \right) + \beta\gamma = -\Psi(\mathbf{s}_{mt}) + \xi_{mt} - \alpha_b b_m - \xi_{mt} \\ - \beta \mathbb{E}_t \left[ -\Psi(\mathbf{s}_{mt+1}) + \xi_{mt+1} - \log(\rho_{mt+1}) \right] \\ - \alpha_p p_{mt} h_{mt+1}^* + \beta \alpha_p \mathbb{E}_t \left[ p_{mt+1} (c_{it+1}^* + h_{mt+2}^*) \right] \\ - \beta \mathbb{E}_t \left[ \left[ \frac{1}{2} \delta h_{mt+1}^* + \mathbf{x}_{it+1} \gamma_x + \varepsilon_{it+1} \right] h_{mt+1}^* \right] \end{aligned}$$

From the law of motion, it holds that  $c_{it+1}^* + h_{mt+2}^* = (1 + \phi)h_{mt+1}^*$ . And from the intensive margin Euler equation specified in 12, the following also holds:

$$\mathbb{E}_t \left[ \frac{1}{2} \delta h_{mt+1}^* + \mathbf{x}_{it+1} \gamma_x + \varepsilon_{it+1} \right] = -\frac{1}{\beta} \alpha_p p_{mt} + \alpha_p (1 + \phi) \mathbb{E}_t [p_{mt+1}] - \mathbb{E}_t \left[ \frac{1}{2} \delta h_{mt+1}^* \right]$$

Therefore, I can rewrite the equation as:

$$\begin{aligned} \log \left( \frac{\rho_{mt}}{1 - \rho_{mt}} \right) + \beta \gamma &= -\Psi(\mathbf{s}_{mt}) + \xi_{mt} - \alpha_b b_m - \xi_{mt} \\ &\quad - \beta \mathbb{E}_t \left[ -\Psi(\mathbf{s}_{mt+1}) + \xi_{mt+1} - \log(\rho_{mt+1}) \right] \\ &\quad - \alpha_p p_{mt} h_{mt+1}^* + \beta \alpha_p (1 + \phi) \mathbb{E}_t [p_{mt+1} h_{mt+1}^*] \\ &\quad - \beta \mathbb{E}_t \left[ \left[ -\frac{1}{\beta} \alpha_p p_{mt} + \alpha_p (1 + \phi) p_{mt+1} - \frac{1}{2} \delta h_{mt+1}^* \right] h_{mt+1}^* \right] \end{aligned}$$

Which can be easily simplified and rearranged to:

$$\begin{aligned} \log \left( \frac{\rho_{mt}}{1 - \rho_{mt}} \right) + \beta \gamma &= -\Psi(\mathbf{s}_{mt}) - \alpha_b b_m \\ &\quad + \beta \mathbb{E}_t [\Psi(\mathbf{s}_{mt+1})] - \beta \mathbb{E}_t [\xi_{mt+1}] \\ &\quad + \beta \mathbb{E}_t [\log(\rho_{mt+1})] + \frac{\beta}{2} \delta (h_{mt+1}^*)^2 \end{aligned}$$

I rearrange the previous equation and employ rational expectations, allowing me write expected values as the sum of realizations and an expectation error, to yield the equation in 4.

## C.3 Instruments

### C.3.1 Prices

To address the potential endogeneity of cattle prices in my regression, I employ a Shift-Share Instrumental Variable (SSIV) approach based on exogenous shocks to Chinese meat imports. This method leverages the substantial and well-documented increase in China's demand for agricultural products over the past decades, particularly since its accession to the World Trade Organization (WTO) in 2001. The instrument is constructed following the methodology of Carreira et al. (2024), which itself is theoretically grounded in the framework of Borusyak et al. (2022). This approach isolates exogenous variation in local outcomes by combining national-level shocks with initial shares of production at the regional level.

The first step in constructing the instrument involves estimating the exogenous shock component of Chinese import growth. Using detailed product-country-year trade data, I estimate an auxiliary regression to identify China-specific import growth rates for each product category<sup>9</sup>  $j$ . This regression excludes Brazilian data to ensure that the shocks are not influenced by domestic

<sup>9</sup>A product is identified by its 6-digit code in the World Customs Organization's (WCO) "Harmonized System" classification. The data used here pertains to fresh, chilled, or frozen meat from bovine animals (HS Chapter 02, Headings 01 and 02).



factors. The regression takes the following form:

$$G_{cj,t} = \gamma_{j,t} + \psi_{\text{China}, j,t} + \epsilon_{cj,t}$$

Here,  $G_{cj,t}$  denotes the growth rate of country  $c$ 's imports of product  $j$  in year  $t$ , measured relative to a base year. The term  $\gamma_{j,t}$  captures year-product fixed effects, varying across both products and years, to account for time-specific characteristics of each product that are invariant across countries. And  $\psi_{\text{China}, j,t}$  represents China-product-specific dummies, which isolate the component of import growth uniquely attributable to Chinese demand for product  $j$  in year  $t$ . The residual term  $\epsilon_{cj,t}$  reflects any unexplained variation. I set the base year to 2000, just prior to China's World Trade Organization (WTO) accession in 2001, following Carreira et al. (2024), to ensure that the base period accurately reflects pre-treatment conditions, unaffected by subsequent policy changes.

After obtaining the estimated China-specific import growth rates ( $\hat{\psi}_{\text{China}, j,t}$ ), I construct the Shift-Share Instrument as:

$$\hat{x}_{m,t} = \sum_j S_{m,j,\bar{t}} \cdot x_{j,\bar{t}} \cdot \hat{\psi}_{\text{China}, j,t} \quad (19)$$

In this expression,  $S_{m,\bar{t}}$  represents the share of production in municipality  $m$  in the base year  $\bar{t}$ . This share is derived from the 1995 agricultural census, ensuring it predates the base year and is unaffected by subsequent shocks.  $x_{j,\bar{t}}$  is the volume of Brazilian exports of product  $j$  to China in the base year. Lastly,  $\hat{\psi}_{\text{China}, j,t}$  denotes the predicted China-specific import growth rates for product  $j$  in year  $t$ , as estimated in the auxiliary regression.

This Shift-Share variable combines the exogenous national-level shocks  $\hat{\psi}_{\text{China}, j,t}$  with initial regional production shares  $S_{m,\bar{t}}$ , ensuring that the instrument captures variation in regional outcomes that stems from China's demand growth rather than from endogenous local factors. The base year values for shares and exports ensure that the comparison baseline for the shocks is pre-determined and independent of the key policy changes that triggered the shock. The use of this instrument is particularly strong for the analysis of cattle prices because Chinese meat imports have been a major driver of global demand shifts, particularly for beef. By isolating the exogenous component of this demand, the Shift-Share instrument acts as a demand shifter (Angrist et al. 2001), providing a credible strategy to address the endogeneity of prices on the supply side.

### C.3.2 Pasture Quality

To address the potential endogeneity in pasture quality, I use the Palmer Drought Severity Index (PDSI) from the previous year as an instrument. Specifically, I take the lowest monthly observation within the year to capture the driest conditions experienced, which have the greatest impact on pasture quality.

The PDSI is a widely used metric for measuring drought severity by comparing current moisture levels to historical averages. I rely on monthly PDSI values calculated by Abatzoglou et al. (2018) in the TerraClimate dataset. These values are derived from a modified Thornthwaite-

Mather climatic water-balance model, which incorporates precipitation (moisture supply), reference evapotranspiration (moisture demand), and soil water storage. The reference evapotranspiration is estimated using the FAO's Penman-Monteith energy balance approach, which accounts for air temperature, solar radiation, air humidity, and wind speed.

The PDSI is a strong instrument for pasture quality because it measures soil moisture availability – a critical factor for vegetation growth and forage production. By reflecting the effects of climatic variability, the PDSI captures how droughts influence vegetation health and productivity. Its standardized design also allows for consistent comparisons of climatic stress on pasture quality across municipalities, regions, biomes, and time.

The use of minimum PDSI values focuses on the most severe drought conditions, such as the driest months or the most intense dry spells. These extreme events are particularly important for pasture quality, as they represent periods when vegetation is most stressed and forage availability is at its lowest. Using lagged values ensures the instrument's exogeneity, as past climatic conditions are predetermined and not influenced by current agricultural decisions or land-use changes.

The key assumption is that drought conditions, as measured by the PDSI, influence herd management and land-use decisions only indirectly through their effect on pasture quality. For example, severe droughts can lead to reduced forage availability, prompting farmers to adjust herd sizes (Skidmore 2023) or clear additional land for grazing (Desbureaux et al. 2018). This indirect relationship supports the validity of the PDSI as an instrument for addressing the endogeneity of pasture quality in the regression framework.

## **D Exercícios empíricos alternativos**

## D.1 Intensive margin: first stage results

Table 6: Intensive margin first stage results

Dependent Variables:	$p_{mt}$	$p_{mt+1}$	Pasture Quality ( $x_{mt+1}$ )
<i>Variables</i>			
$ssiv_{mt}$	-19.93*** (3.417)	-21.23*** (3.645)	0.0140*** (0.0021)
$ssiv_{mt+1}$	13.23*** (2.261)	14.08*** (2.411)	-0.0092*** (0.0014)
pdsi_min	0.1117*** (0.0201)	0.1100*** (0.0207)	$5.68 \times 10^{-5}$ *** ( $1 \times 10^{-5}$ )
Year	79.05*** (0.9454)	59.88*** (0.9916)	0.0075*** (0.0003)
Temperature	✓	✓	✓
Past. Suit.	✓	✓	✓
Mkt. Acc.	✓	✓	✓
Transp. Cost	✓	✓	✓
<i>Fixed-effects</i>			
Biome	✓	✓	✓
<i>Fit statistics</i>			
Observations	6,487	6,487	6,487
F-test	309.45	173.59	98.484
F-test (1st stage)	49.981	47.741	38.057

Clustered (Municipality) standard-errors in parentheses

Signif. Codes: \*\*\*: 0.01, \*\*: 0.05, \*: 0.1

## D.2 Intensive margin with municipality fixed effects

Table 7: Intensive margin FE regression results

Dependent Variable:	OLS	$h_{mt+1}$	IV
<i>Variables</i>			
$p_{mt}$	-0.0004*** ( $6.4 \times 10^{-5}$ )		-0.0004*** (0.0002)
$p_{mt+1}$	0.0004*** ( $6.18 \times 10^{-5}$ )		0.0004** (0.0002)
Pasture Quality ( $x_{mt+1}$ )	0.0953*** (0.0155)		0.3666*** (0.0658)
Year	0.0047*** (0.0014)		0.0069*** (0.0024)
Temperature	✓		✓
Past. Suit.			
Mkt. Acc.	✓		✓
Transp. Cost			
<i>Fixed-effects</i>			
Municipality	✓		✓
<i>Fit statistics</i>			
Observations	6,487		6,487
F-test	5,689.8		7,821.2
<i>Clustered (Municipality) standard-errors in parentheses</i>			
<i>Signif. Codes: ***: 0.01, **: 0.05, *: 0.1</i>			

### D.3 Extensive margin: first stage results

Table 8: Extensive margin first stage results

Dependent Variable:	Pasture Quality ( $\beta x_{mt+1} - x_{mt}$ )
<i>Variables</i>	
pdsi_min	$-5.9 \times 10^{-5***}$ ( $2.07 \times 10^{-6}$ )
$\frac{\beta}{2}(h_{mt+1})^2$	$-0.0301***$ (0.0072)
$b_m$	$-0.0002***$ ( $9.17 \times 10^{-6}$ )
$(\beta + (\beta - 1)t)$	0.0005 (0.0010)
Temperature	✓
Past. Suit.	✓
Mkt. Acc.	✓
Transp. Cost	✓
<i>Fixed-effects</i>	
Biome	✓
<i>Fit statistics</i>	
Observations	6,210
F-test	106.02
F-test (1st stage)	715.73
<i>Clustered (Municipality) standard-errors in parentheses</i>	
<i>Signif. Codes: ***: 0.01, **: 0.05, *: 0.1</i>	

## D.4 Extensive margin exercise with survey data

Table 9: Extensive margin regression with survey data


Dependent Variable:	$\log\left(\frac{\rho_{mt}}{1-\rho_{mt}}\right) - \beta \log(\rho_{mt+1}) + \beta\gamma$	
	OLS	IV
<i>Variables</i>		
$\frac{\beta}{2}(h_{mt+1})^2$	0.1171*** (0.0331)	0.3427*** (0.1006)
Pasture Quality ( $\beta x_{mt+1} - x_{mt}$ )	1.382*** (0.0860)	10.76*** (0.8078)
$b_m$	-0.0004*** ( $6.79 \times 10^{-5}$ )	0.0013*** (0.0002)
$(\beta + (\beta - 1)t)$	-0.0424*** (0.0047)	-0.0660*** (0.0054)
Temperature	✓	✓
Past. Suit.	✓	✓
Mkt. Acc.	✓	✓
Transp. Cost.	✓	✓
<i>Fixed-effects</i>		
Biome	✓	✓
<i>Fit statistics</i>		
Observations	64,736	64,736
F-test	6.6588	6.7972

Clustered (Municipality) standard-errors in parentheses

Signif. Codes: \*\*\*: 0.01, \*\*: 0.05, \*: 0.1

## D.5 Pasture recovery effect on abatements

Figure 5: Pasture recovery counterfactual ( $CO_2$  Abatement)



This figure plots the potential  $CO_2$  abatement from a pasture recovery counterfactual. The X-axis shows the minimum share of high-quality pastures set by the policy in each municipality. The Y-axis shows the carbon abatement relative to the baseline emissions for each policy level. Panel (a) shows the disaggregation between Borlaug and Jevons effects, while panel (b) exhibits the net effect.